Integração de Aprendizado de Máquina em Redes Quânticas: Uma Plataforma de Controle Auditável com Modelos Acoplados

Alexandre O. S. Santos[1,2,3], **João M. S. Souza**[2,3], **Otto Menegasso Pires**[2,3], **Leonardo S. Almeida**[1], **Gilson Amorim Carvalho**[1]

[1]Centro Universitário Jorge Amado (Unijorge)
Av. Luís Viana Filho, 6775 – Paralela – Salvador – BA – Brasil

[2]Quantum Industrial Innovation – QuIIN
Senai CIMATEC – Salvador, BA – Brasil

[3]Latin America Quantum Computing Center – LAQCC
Senai CIMATEC – Salvador, BA – Brasil

alexandreoliversan1@gmail.com, joao.marcelo@fieb.org.br,
otto.pires@fieb.org.br, leoalm@gmail.com

Abstract. *Operating a quantum network requires continuous decisions: when to purify entangled pairs, how to compensate polarization drift, how to share resources between classical and quantum traffic and how to tune key-distribution parameters. Machine-learning models have been proposed for each of these tasks, but a model that performs well offline is not yet a controller. This work presents ORION-Q, a control platform for simulated quantum networks in which learned models are optional, verified and compared against simple baselines before they can influence decisions. The platform admits five of six externally trained components (ten configurations; the sixth, a detector, stays blocked) through hash-pinned archives without unsafe deserialization, reproduces their reference outputs, evaluates them in shadow mode and exposes an auditable activation flow with review, approval, read-back and rollback. A preliminary study tested whether classical WDM telemetry could forecast entanglement fidelity: under a frozen ten-seed protocol, none of three neural admission controllers outperformed persistence, and public measured data confirmed that classical coexistence degrades QBER and secret-key rate but provided no paired temporal target. In shadow campaigns, a Ridge polarization compensator reduced prediction error against persistence by 11.6–17.4% in three of six artificial scenarios, whereas a timing synchronizer met the predefined criteria in only one of six.* ***[PENDENTE: closed-loop result]*** *All results are simulated and no physical actuation is performed.*

Resumo. *Operar uma rede quântica exige decisões contínuas: quando purificar pares emaranhados, como compensar a deriva de polarização, como dividir recursos entre tráfego clássico e quântico e como ajustar parâmetros de distribuição de chaves. Modelos de aprendizado de máquina já foram propostos para*

cada uma dessas tarefas, mas um modelo com bom desempenho offline ainda não é um controlador. Este trabalho apresenta o ORION-Q, uma plataforma de controle para redes quânticas simuladas na qual modelos aprendidos são opcionais, verificados e comparados a baselines simples antes de influenciar decisões. A plataforma admite cinco de seis componentes treinados externamente (dez configurações; o sexto, um detector, permanece bloqueado) por meio de pacotes com identidade SHA-256 e sem desserialização insegura, reproduz suas saídas de referência, avalia-os em modo shadow e oferece um fluxo de ativação auditável, com revisão, aprovação, leitura de confirmação e reversão. Um estudo preliminar testou se a telemetria clássica WDM poderia prever a fidelidade do emaranhamento: sob protocolo congelado com dez sementes, nenhum dos três controladores neurais de admissão superou a persistência, e dados públicos medidos confirmaram que a coexistência clássica degrada QBER e taxa de chave secreta, sem oferecer um alvo temporal pareado. Em campanhas shadow, um compensador de polarização Ridge reduziu o erro de previsão frente à persistência entre 11,6% e 17,4% em três de seis cenários artificiais, enquanto um sincronizador temporal atendeu aos critérios predefinidos em apenas um de seis. ***[PENDENTE: resultado em laço fechado]*** *Todos os resultados são simulados e nenhuma atuação física é realizada.*

Palavras-chave: Redes Quânticas, Plano de Controle, Aprendizado de Máquina, Distribuição Quântica de Chaves, Repetidores Quânticos, Avaliação Reprodutível.

1. Introdução

A Internet Quântica pretende distribuir emaranhamento e chaves secretas entre nós distantes, complementando a infraestrutura clássica de telecomunicações [Kimble 2008, Wehner et al. 2018]. Como fótons sofrem atenuação exponencial na fibra e o estado quântico não pode ser simplesmente amplificado, o alcance depende de repetidores quânticos, que combinam geração, armazenamento, purificação e troca de emaranhamento (*entanglement swapping*) [Briegel et al. 1998, Dür et al. 1999, Azuma et al. 2023]. Na era NISQ (*Noisy Intermediate-Scale Quantum*), essas operações são imperfeitas e consomem recursos escassos, como tempo de memória e operações de dois qubits [Preskill 2018].

Operar uma rede desse tipo exige decisões contínuas. Um repetidor precisa decidir se vale a pena purificar um par cuja fidelidade pode estar abaixo do limiar útil. Um enlace de distribuição quântica de chaves (QKD) com codificação em polarização precisa compensar a rotação lenta e aleatória introduzida pela birrefringência da fibra [Xavier et al. 2008]. Quando canais clássicos e quânticos compartilham a mesma fibra, o espalhamento Raman e outras contribuições de ruído degradam a taxa de erro quântico (QBER) e a taxa de chave secreta (SKR) [Eraerds et al. 2010, Patel et al. 2012, Thomas et al. 2023], o que obriga o operador a equilibrar os dois tipos de tráfego. Para cada uma dessas tarefas já foram propostos modelos de aprendizado de máquina, por exemplo para roteamento de emaranhamento por aprendizado por reforço [Le and Nguyen 2022].

Um modelo com bom desempenho *offline*, porém, ainda não é um controlador. Para influenciar decisões de rede, ele precisa de contratos de entrada e saída explícitos,

de comparação com *baselines* simples, como a persistência (repetir o último valor observado), e de mecanismos que impeçam um modelo não validado de agir. Sem isso, não é possível distinguir um ganho real de um artefato do cenário de treino. Este trabalho trata dessa lacuna com a seguinte pergunta de pesquisa:

> *Como integrar modelos de aprendizado de máquina a um plano de controle de rede quântica simulada de forma que cada modelo seja opcional, verificável e comparado a baselines antes de influenciar decisões, e que evidência esses modelos produzem nessa integração?*

O trabalho começou com uma hipótese mais estreita: a de que a telemetria óptica clássica de multiplexação por comprimento de onda (WDM) permitiria prever a fidelidade futura de pares emaranhados e, assim, evitar purificações inúteis. O estudo preliminar descrito na Seção 5 testou essa hipótese com protocolos progressivamente mais rigorosos e encontrou limites claros. Esse resultado deslocou a pergunta de "qual rede neural prevê melhor" para "como integrar, comparar e governar diferentes modelos", que é o foco atual.

As contribuições são:

1. a arquitetura do ORION-Q, um plano de controle simulado com supervisor de segurança independente, trilhas de evidência separadas e diário de auditoria;
2. a admissão de cinco componentes de aprendizado de máquina treinados externamente (dez configurações), com verificação de identidade, leitura segura e paridade numérica com as saídas originais, e o bloqueio justificado de um sexto componente;
3. um fluxo de ativação auditável, com preparação, revisão, aprovação, ativação, leitura de confirmação, reversão e recuperação;
4. uma metodologia de avaliação em três níveis (paridade, *shadow* e laço fechado) com protocolo congelado e *baselines* obrigatórios;
5. resultados empíricos, inclusive negativos, registrados de forma verificável.

2. Justificativa e Objetivos

2.1. Justificativa

Recursos de um repetidor quântico são escassos: cada tentativa de purificação consome pares armazenados e tempo de memória, e uma decisão errada não pode ser desfeita. Ao mesmo tempo, a literatura de aprendizado de máquina para redes quânticas costuma relatar o desempenho de um modelo isolado, em seu próprio ambiente de treino. Falta uma camada de engenharia que permita responder, para cada modelo, três perguntas antes de usá-lo: ele reproduz o comportamento declarado? Ele supera uma regra simples nas mesmas condições? O que acontece se ele for ativado e precisar ser revertido? Uma plataforma que torne essas respostas explícitas reduz o risco de adotar modelos que não agregam valor e cria uma base reprodutível para comparar novos métodos.

2.2. Objetivo Geral

Desenvolver e avaliar uma plataforma de software para controle de redes quânticas simuladas que integre modelos de aprendizado de máquina de forma opcional, auditável e comparada a *baselines*.

2.3. Objetivos Específicos

- Formalizar contratos de entrada, saída e ação para funções de controle: admissão de purificação, compensação de polarização, sincronização, ajuste de taxa de chave, roteamento e alocação de recursos.
- Admitir modelos treinados externamente com verificação de identidade, sem desserialização insegura e com paridade numérica frente às saídas de referência.
- Implementar um supervisor de segurança independente e um fluxo de ativação com revisão, aprovação, ativação, confirmação e reversão.
- Avaliar os modelos em modo *shadow* e em laço fechado contra persistência e *baselines* clássicos, com protocolo definido antes da execução.
- Registrar a evidência e os limites de cada modelo em um registro verificável.

3. Fundamentação Teórica

3.1. Repetidores, purificação e troca de emaranhamento

Um par emaranhado ruidoso pode ser descrito por um estado de Werner com fidelidade F em relação ao estado de Bell $|\Phi^+\rangle$. O protocolo BBPSSW consome dois pares de fidelidade F e, com probabilidade de sucesso p_{suc}, produz um par de fidelidade F' [Bennett et al. 1996]:

$$F' = \frac{F^2 + \frac{1}{9}(1-F)^2}{p_{\mathrm{suc}}}, \qquad p_{\mathrm{suc}} = F^2 + \frac{2}{3}F(1-F) + \frac{5}{9}(1-F)^2. \tag{1}$$

O protocolo só melhora a fidelidade quando $F > 1/2$; abaixo disso, a tentativa consome recursos sem benefício. A troca de emaranhamento entre dois pares de Werner com fidelidades F_1 e F_2 produz

$$F_{\mathrm{out}} = F_1 F_2 + \frac{(1-F_1)(1-F_2)}{3}, \tag{2}$$

de modo que a fidelidade decai rapidamente ao longo de vários saltos [Briegel et al. 1998, Dür et al. 1999]. Enquanto aguardam, os qubits armazenados sofrem relaxação de amplitude e de fase, caracterizadas pelos tempos T_1 e T_2 [Nielsen and Chuang 2010].

3.2. QKD e coexistência com canais clássicos

No protocolo BB84 [Bennett and Brassard 1984] com estados-isca (*decoy states*) [Lo et al. 2005], a segurança depende da QBER medida e a SKR resulta de uma estimativa a partir dos observáveis de detecção. Quando sinais clássicos de alta potência

compartilham a fibra, fótons gerados por espalhamento Raman caem na banda do canal quântico, elevam a QBER e reduzem a SKR [Eraerds et al. 2010, Patel et al. 2012]. O projeto do plano espectral e da potência clássica é, portanto, um compromisso entre os dois serviços [Thomas et al. 2023].

3.3. Deriva de polarização

Em QKD com codificação em polarização, a birrefringência da fibra varia com a temperatura e com vibrações, rotacionando o estado de polarização. Essa rotação pode ser representada por uma matriz $R(t) \in SO(3)$ que atua no vetor de Stokes na esfera de Poincaré. Se o estado recebido estiver desalinhado de um ângulo θ em relação à base de medição, a probabilidade de erro de projeção é

$$e(\theta) = \sin^2(\theta/2), \tag{3}$$

que se soma à QBER. Sistemas práticos usam controle ativo de polarização para estimar e compensar $R(t)$ [Xavier et al. 2008]. Um preditor da rotação futura pode antecipar essa compensação.

3.4. Modelos e baselines

Os componentes avaliados usam regressão Ridge [Hoerl and Kennard 1970], perceptrons multicamadas (MLP), redes LSTM [Hochreiter and Schmidhuber 1997] e redes ator-crítico de aprendizado por reforço [Sutton and Barto 2018]. Em séries temporais com forte autocorrelação, a persistência ($\hat{x}_{t+h} = x_t$) é um *baseline* difícil de superar; por isso, todo modelo é comparado a ela e a pelo menos uma regra simples adicional. As comparações entre vários candidatos usam correção de Holm [Holm 1979]; equivalência é testada pelo procedimento TOST [Schuirmann 1987]; e proporções usam intervalos de Wilson [Wilson 1927].

4. Trabalhos Relacionados

Simuladores de eventos discretos, como o SeQUeNCe [Wu et al. 2021] e o NetSquid [Coopmans et al. 2021], modelam componentes físicos, protocolos e pilhas de rede quântica com alto nível de detalhe. Eles são a base usual para treinar e testar políticas de controle, mas não tratam da governança de modelos aprendidos dentro de um plano de controle: verificação de identidade dos pesos, comparação obrigatória com *baselines*, ativação reversível e auditoria. O ORION-Q é complementar a esses simuladores; os modelos avaliados aqui foram treinados no SeQUeNCe.

A RFC 9340 [Kozlowski et al. 2023] descreve princípios arquiteturais para uma Internet Quântica, incluindo a separação entre plano de dados e de controle e o papel da sinalização clássica. Esses princípios orientam a arquitetura proposta, embora o documento seja informativo e não uma especificação normativa.

Na aplicação de aprendizado de máquina, o aprendizado por reforço profundo já foi usado para roteamento de emaranhamento [Le and Nguyen 2022]. Na camada física, o controle ativo de polarização [Xavier et al. 2008] e o projeto de redes que coexistem

com tráfego clássico [Thomas et al. 2023, Patel et al. 2012] são problemas estabelecidos, com soluções clássicas que funcionam como *baselines* naturais. Na literatura consultada, não identificamos trabalhos que integrem modelos de diferentes funções em um mesmo plano de controle com admissão verificável, avaliação *shadow*, comparação obrigatória com persistência e ativação auditável; essa é a lacuna explorada aqui.

5. Estudo Preliminar: Admissão Preditiva com Telemetria WDM

5.1. Hipótese e formulação

A hipótese inicial foi que parâmetros ópticos clássicos observáveis sem medir o estado quântico (deriva de fase, potência, OSNR, BER, perda e latência) estariam causalmente acima dos processos de decoerência e, portanto, permitiriam prever a fidelidade futura $F(t + \Delta t)$ de um par e evitar purificações destinadas a falhar. A formulação original propôs uma métrica de vida útil de coerência restante; nos experimentos, porém, o alvo efetivamente estimado foi $F(t + \Delta t)$ e a decisão avaliada foi a admissão da purificação.

Para penalizar mais a admissão de um par cuja fidelidade real está abaixo do limiar (falso positivo, FP) do que o descarte de um par útil, usou-se uma perda quadrática sensível ao custo (CS-MSE):

$$L_{CS} = \frac{1}{N} \sum_{i=1}^{N} \left(F_i - \hat{F}_i \right)^2 \left[1 + \lambda \, \mathbb{I}(\mathrm{FP}_i) \right], \tag{4}$$

em que $\mathbb{I}(\mathrm{FP}_i)$ vale 1 quando a previsão admite um par com fidelidade real abaixo do limiar. O indicador atua apenas como peso do erro quadrático, que permanece diferenciável.

5.2. Fase 1: ruído sintético

Na primeira fase, a deriva de fase do canal foi gerada por um processo de Ornstein-Uhlenbeck [Uhlenbeck and Ornstein 1930], que é gaussiano e markoviano, e uma rede EdgeLSTM foi treinada com a perda da Eq. 4 para diferentes valores de λ, com dez sementes. A Tabela 1 e a Figura 1 mostram o compromisso resultante.

Tabela 1. Efeito do peso λ da CS-MSE sobre as decisões de admissão (média $\pm$ desvio-padrão, dez sementes). O *baseline* admite todos os pares.

	Descartes	Tentativas	Rendimento	$\Delta P_{\text{úteis}}$	FP	MAE
Baseline	0	796	26,38%	–	586,0	–
$\lambda = 1$	$528{,}0 \pm 176{,}9$	$268{,}0 \pm 176{,}9$	$86{,}2 \pm 20{,}5\%$	$-14{,}8 \pm 8{,}9$	$72{,}8 \pm 171{,}4$	$0{,}095 \pm 0{,}053$
$\lambda = 5$	$680{,}3 \pm 65{,}6$	$115{,}7 \pm 65{,}6$	$90{,}9 \pm 10{,}7\%$	$-102{,}8 \pm 62{,}7$	$8{,}5 \pm 10{,}5$	$0{,}170 \pm 0{,}010$
$\lambda = 10$	$738{,}3 \pm 51{,}7$	$57{,}7 \pm 51{,}7$	$90{,}1 \pm 17{,}0\%$	$-153{,}9 \pm 53{,}0$	$1{,}6 \pm 3{,}1$	$0{,}175 \pm 0{,}003$
$\lambda = 20$	$756{,}1 \pm 33{,}6$	$39{,}9 \pm 33{,}6$	$100{,}0 \pm 0{,}0\%$	$-170{,}1 \pm 33{,}6$	$0{,}0 \pm 0{,}0$	$0{,}175 \pm 0{,}004$

Com $\lambda = 10$, os falsos positivos caem de 586 para $1{,}6 \pm 3{,}1$, ao custo de $153{,}9 \pm 53{,}0$ pares úteis a menos e de um MAE maior, pois a perda desloca as previsões para baixo de propósito. O rendimento (pares úteis por tentativa) sobe porque o controlador

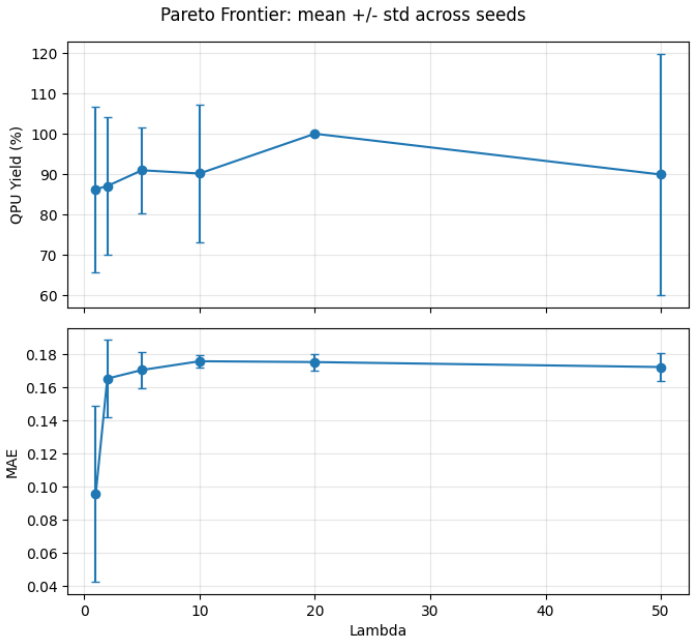


Figura 1. Rendimento da QPU (acima) e MAE (abaixo) em função de λ; as barras indicam o desvio-padrão entre dez sementes.

tenta muito menos; sozinho, esse indicador favorece políticas que quase nunca agem. A escolha de λ depende, portanto, do custo relativo entre um falso positivo e um par perdido. Em uma comparação adicional com média móvel, LSTM com MSE, XGBoost e Random Forest, a EdgeLSTM com CS-MSE teve o menor número de falsos positivos e o menor custo físico ponderado, enquanto a média móvel teve o maior escore de decisão linear. Como o custo ponderado atribui peso 100 aos falsos positivos, esse ordenamento reflete a escolha dos pesos, e não uma superioridade geral do modelo.

5.3. Fase 2: canal causal e topologia multi-salto

Na segunda fase, a telemetria passou a derivar dos mesmos parâmetros físicos que degradam o par (distância, perda, eficiência de transmissão, BER, T_1 e T_2), e a fidelidade foi extraída de uma simulação de matriz densidade no Qiskit Aer [Javadi-Abhari et al. 2024], com erro despolarizante e amortecimentos de amplitude e de fase. Um detalhe de implementação foi decisivo: o transpilador remove portas ociosas por padrão e, com isso, apagava a decoerência simulada; o nível de otimização foi fixado em zero para preservá-la. Como fótons perdidos geram rodadas com $F = 0$, misturadas a rodadas com fidelidade degradada, a rede foi dividida em duas saídas (DualHead): a probabilidade de chegada do fóton, treinada com entropia cruzada binária, e a fidelidade condicionada à chegada, treinada com a CS-MSE. A troca de emaranhamento foi validada contra a Eq. 2.

A Figura 2 mostra que o filtro por aprendizado de máquina elevou a taxa de sucesso das tentativas admitidas de 70% para 98% em um salto e de 32% para 87% em três saltos, contra 99% do oráculo. Essa taxa é condicionada à admissão: ela não mede quantos pares úteis foram entregues, e um filtro muito conservador pode ter alta taxa de sucesso e baixa vazão. Por isso, a fase seguinte passou a usar a utilidade líquida por

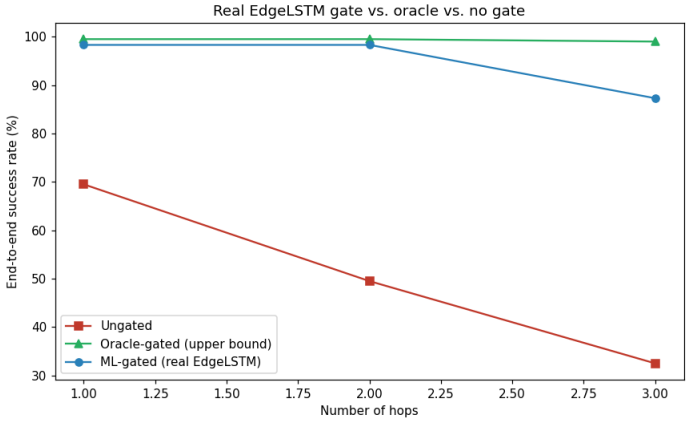


Figura 2. Taxa de sucesso fim a fim entre as tentativas admitidas, para admissão sem filtro, com filtro EdgeLSTM e com oráculo, em um a três saltos.

chegada de par como métrica primária.

5.4. Reavaliação com protocolo congelado

Uma primeira campanha com dez sementes indicou rendimento médio de 50,5% (IC95% [46,5; 54,4]) para a DualHead, contra 42,7% (sem filtro), 43,1% (reativo) e 43,0% (LSTM de saída única), com $p < 0{,}001$ após Holm. Essa comparação, porém, não incluía a persistência nem calibrava a incerteza fora do conjunto de teste. Um protocolo mais rigoroso foi então definido antes da execução: ajuste do modelo em um prefixo temporal, calibração da incerteza e dos limiares em um prefixo posterior, congelamento da política com hash e avaliação única em dez sementes novas. Duas correções de semântica precederam o teste: purificação e troca passaram a ser tarefas mutuamente exclusivas, e o limiar passou a ser o da fidelidade de entrada que produz saída útil pela Eq. 1 (0,625 para uma saída de 0,65).

Tabela 2. Avaliação com protocolo congelado (médias de dez sementes novas). Utilidade líquida por chegada de par; comparação pareada com persistência e correção de Holm.

Controlador	MAE	Utilidade líquida	Diferença vs. persistência	p (Holm)
Persistência	0,290	0,067	–	–
EdgeLSTM (pontual)	0,316	0,047	−0,020	1,000
EdgeLSTM (probabilística)	0,257	−0,074	−0,140	1,000
EdgeLSTM DualHead	0,245	−0,134	−0,201	1,000
Oráculo (diagnóstico)	0,000	0,364	–	–

Nenhuma das três comparações foi positiva e significativa (Tabela 2); todas as médias favoreceram a persistência. A DualHead teve o menor MAE entre os modelos neurais, mas a pior utilidade: prever melhor não se converteu em decidir melhor. A distância até o oráculo mostra que a informação sobre a fidelidade futura teria valor; o que faltou foi um preditor que a extraísse de forma útil nesse cenário.

Dados medidos públicos levaram a conclusões compatíveis. Em 65.733 registros de telemetria óptica de um *testbed* da Scuola Superiore Sant'Anna[1], a telemetria WDM passada não melhorou a previsão de OSNR ou BER além do histórico do próprio alvo em nenhum dos 16 testes. Em varreduras com equipamento Toshiba publicadas pelo projeto IrelandQCI[2], a coexistência com sinal clássico aumentou a QBER em 0,0132 ($p = 0{,}0015$ após Holm) e reduziu $\log(1 + \mathrm{SKR})$ em 0,360 ($p = 0{,}011$); a mesma direção apareceu em dados da Universidade de Bristol[3]. Nesses dados, uma regra monotônica baseada somente na potência clássica ordenou a dominância conjunta QBER–SKR melhor do que uma rede neural de três saídas (acurácia 0,678 contra 0,563). Nenhuma base pública combinava telemetria WDM ordenada no tempo com um alvo quântico futuro medido no mesmo enlace; a hipótese temporal original permanece, portanto, não testada com dados físicos.

5.5. Latência de inferência

A inferência da EdgeLSTM em CPU levou $\tau_{\mathrm{inf}} \approx 0{,}5$ ms. Com o valor $T_2 = 30\ \mu$s adotado na simulação, a razão τ_{inf}/T_2 fica muito acima de 1: o par se degradaria durante a própria decisão. Como T_2 varia muito entre plataformas de memória [Krutyanskiy et al. 2023], essa conclusão vale para o valor simulado e indica que, para memórias de coerência curta, a inferência precisaria de *hardware* dedicado.

5.6. Consequência para o trabalho

O estudo preliminar mostrou que a qualidade de um modelo só pode ser julgada contra *baselines* simples, com protocolo congelado e métricas operacionais, e que métricas isoladas, como rendimento ou MAE, podem enganar. Em vez de buscar um único preditor melhor, o trabalho passou a construir uma plataforma na qual qualquer modelo seja submetido a esse tipo de avaliação antes de influenciar a rede.

6. Arquitetura da Plataforma ORION-Q

6.1. Laço de controle

A Figura 3 resume a arquitetura. As entradas (sintéticas, *replay* ou arquivo JSON medido) seguem o mesmo contrato e carregam proveniência por observação (medida, simulada, derivada ou prevista); trocar a fonte não concede nenhuma permissão adicional. Cada ciclo produz um *snapshot* tipado do estado da rede, com carimbo de tempo, versão e verificação de integridade. A política ativa propõe uma ação; um supervisor de segurança independente pode vetá-la, por exemplo forçando HALT quando a entrada está fora do domínio de treino; e o executor aplica a decisão somente nos modos *shadow* ou simulação. Não existe modo físico: todo registro carrega o invariante `physical_action_performed=false`. Todos os ciclos são gravados em um diário SQLite com hashes.

[1] `https://github.com/Network-And-Services/optical-failure-dataset`
[2] `https://doi.org/10.5281/zenodo.21132088`
[3] `https://doi.org/10.5523/bris.61193flfovbn2puknndsr3qm5`

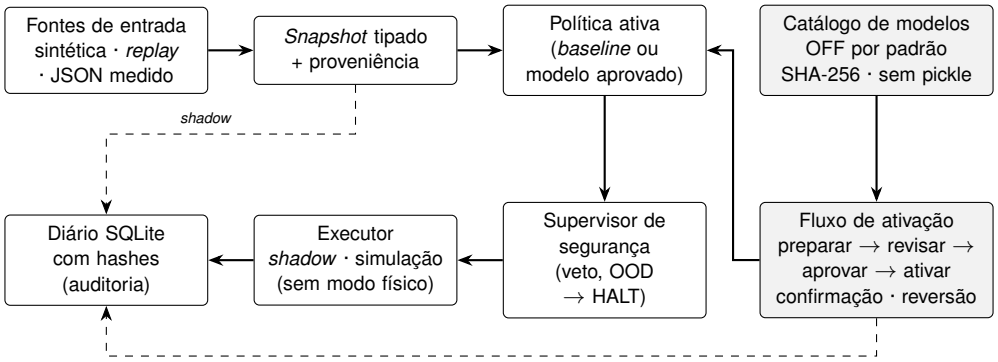


Figura 3. Arquitetura do ORION-Q. Linhas contínuas: laço de controle; tracejadas: registros de auditoria das sessões *shadow* (recomendações registradas, nunca aplicadas) e do fluxo de ativação.

6.2. Trilhas de evidência

A plataforma separa três trilhas: telemetria óptica medida, usada somente como observação de saúde do enlace; QBER e SKR medidos, válidos apenas dentro da grade experimental de origem; e fidelidade de Bell simulada, restrita ao ambiente de controle simulado. A conversão de BER, QBER ou SKR em fidelidade de Bell é proibida, e qualquer tentativa de usar evidência óptica ou de QKD para disparar PURIFY ou SWAP é recusada. O registro formal de reivindicações do trabalho usa essa mesma separação: cada afirmação tem um selo (suportada, exploratória, não suportada, refutada para os modelos avaliados ou não testada) e aponta para evidências com hash, verificadas automaticamente.

6.3. Admissão de modelos

Modelos externos entram como pacotes ZIP cuja identidade é fixada por SHA-256; qualquer alteração exige nova revisão. O conteúdo é lido em memória, sem extração, sem importar os *scripts* fornecidos e sem desserializar *pickle*: os pesos são lidos como *arrays* numéricos (`allow_pickle=False`), e objetos, valores não finitos e tamanhos acima dos limites são recusados. Cada componente ganha um adaptador com contrato explícito de domínio, cadência e horizonte, e só é admitido se reproduzir as saídas de referência fornecidas com o modelo. O catálogo resultante tem onze entradas: dez configurações admitidas e um detector bloqueado por usar *pickle*. Todas ficam desligadas por padrão, e a plataforma funciona sem nenhum peso externo.

6.4. Modos de uso de um modelo

Um modelo admitido pode ser usado em três níveis. Na sessão *offline*, o operador executa o modelo sobre uma janela explícita e compara a saída com a persistência. No modo *shadow*, um produtor artificial independente gera observações contínuas; o modelo recomenda ações, que são registradas e avaliadas, mas nunca aplicadas, e o produtor não reage a elas. No laço fechado, a ação do modelo altera o estado simulado; esse nível só é acessível pelo fluxo de ativação descrito a seguir.

6.5. Fluxo de ativação auditável

Nenhuma política nova entra em vigor sem cinco etapas explícitas. (i) A *preparação* vincula a proposta à sessão de execução, à configuração observada e ao hash da topologia, e expira em 300 s. (ii) A *revisão* confere se esse contexto ainda é válido. (iii) A *aprovação* registra uma declaração explícita do operador, com confirmação inicialmente desmarcada; ela não autentica o operador nem autoriza atuação física. (iv) A *ativação* ocorre sob bloqueio do ciclo, dentro de uma transação SQLite: o contexto é relido, os hashes são conferidos e a referência da política é trocada; se a confirmação da gravação falhar ou for ambígua, a política anterior é restaurada e novos ciclos ficam bloqueados até uma recuperação explícita. (v) A *leitura de confirmação* distingue o registro histórico (COMMITTED) do estado vigente (ACTIVE). A *reversão* prepara a política anterior e exige nova revisão, aprovação e ativação. Um painel de auditoria reconstrói cada decisão separando a ação pretendida, o veto do supervisor e o resultado do executor. **[PENDENTE: extensão do fluxo para ativar os modelos do catálogo, hoje implementado para o limiar da política do repetidor]**

6.6. Implementação

A plataforma foi escrita em Python, com PyTorch [Paszke et al. 2019] e Qiskit Aer [Javadi-Abhari et al. 2024] no núcleo científico (cerca de 23 mil linhas), uma camada de plano de controle e console nativo em PySide6 (cerca de 32 mil linhas) e um pacote executável para Windows. A suíte automatizada tem 3.460 testes **[PENDENTE: atualizar a contagem de aprovação após a correção do CI]**, e o registro de reivindicações é verificado por 69 checagens automáticas.

7. Modelos Acoplados

Os seis componentes da Tabela 3 foram desenvolvidos pelo autor em trabalho anterior sobre o simulador SeQUeNCe **[PENDENTE: inserir referência dos dois artigos/pacotes `modelo_qkd_ml` e `qnet_network`]**. A DualHead do estudo preliminar também está disponível como pacote congelado, com leitura sem *pickle* e *replay* no painel.

Tabela 3. Componentes admitidos, contratos e verificação de paridade.

Componente	Modelo	Entrada → saída	Paridade conferida
Sincronizador QKD	Ridge	8 *offsets* e temperaturas (passo 1 s) → *offset* em +2 s	593 previsões
Ator de taxa de chave	Ator 16-64-64-9	observáveis *decoy-state* → 1 de 9 ajustes limitados	features, probabilidades e ações em 40 períodos
Compensador de polarização	Ridge e MLP, 2 regimes (4 *checkpoints*)	48 features de rotações SO(3) (2 ms) → rotação em +40 ms	40 mil saídas e 48 janelas
Roteamento e temporização	Ator-crítico, 2 *checkpoints*	11 features de estado + 23 por ação → pontuação por ação	24 exemplos
Alocador híbrido	Lei de controle + persistência ou Ridge	11 enlaces, passo 5 s, fila de 30 s → admissão por enlace	1.440 passos e 20 *snapshots*
Detector de anomalias QKD	*Boosting*	17 features → classe	bloqueado (*pickle*)

A documentação dos próprios modelos impõe limites que a plataforma preserva.

O sincronizador tinha vantagem desprezível sobre a persistência no ambiente original. O roteador não superava a melhor heurística no regime documentado e entra como candidato, não como melhoria comprovada. O ganho do alocador relatado no trabalho original vem da lei de controle frente à admissão estática, e não do componente aprendido. O compensador Ridge/MLP superava um filtro alfa-beta reajustado no regime calibrado, mas piorava quando transplantado para o outro regime; por isso os pesos de um regime não substituem os do outro. Por fim, as features de roteamento geradas no ORION-Q são ilustrativas e não reproduzem a normalização do simulador original.

8. Metodologia de Avaliação

8.1. Níveis de evidência

A avaliação segue três níveis cumulativos: (i) *paridade*, em que o adaptador reproduz as saídas de referência do pacote original; (ii) *shadow*, em que o modelo prevê sobre um produtor artificial independente e é pontuado contra alvos observados depois; e (iii) *laço fechado*, em que a ação do modelo altera o estado simulado e o efeito é medido na variável controlada. Um nível superior não é inferido de um inferior: paridade não indica ganho, e erro de previsão menor não indica melhor controle.

8.2. Protocolo das campanhas shadow

Cada campanha teve protocolo gravado com hash antes da primeira inferência, sementes fixas (100 a 109) e nenhum treino, ajuste ou seleção sobre os resultados. O sincronizador foi avaliado em seis cenários artificiais com 128 quadros por execução, contra persistência e média dos oito *offsets* anteriores. O compensador foi avaliado em seis cenários, quatro *checkpoints* e dez sementes (240 execuções), com erro medido pelo ângulo geodésico em SO(3), contra persistência e contra velocidade angular constante estimada dos 15 incrementos anteriores. Um cenário só foi considerado favorável quando o modelo reduziu o erro médio em pelo menos 5% contra cada *baseline*, venceu em pelo menos 8 de 10 sementes e manteve cobertura de pelo menos 90% em todas as sementes. Esses são critérios descritivos de engenharia, não testes de significância.

8.3. Protocolo em laço fechado

Para o compensador de polarização, a planta simulada aplica a correção proposta à rotação da fibra, e o sistema observa apenas a rotação residual. A métrica primária é o ângulo residual θ; a secundária é a contribuição de desalinhamento para a QBER, $e(\theta)$ (Eq. 3). Os comparadores são: sem compensação, persistência e velocidade angular constante. A campanha cobre os dois regimes, quatro cenários (suave, reversão térmica, degrau e ruído) e dez sementes, com teste pareado por semente e correção de Holm. **[PENDENTE: confirmar protocolo congelado e hash antes da execução]**

9. Resultados

9.1. Paridade

As dez configurações admitidas reproduziram as saídas de referência de seus pacotes nos volumes indicados na Tabela 3, e o detector permaneceu bloqueado. A paridade confirma que a plataforma executa os modelos como foram entregues; ela não é evidência de desempenho.

9.2. Campanhas shadow

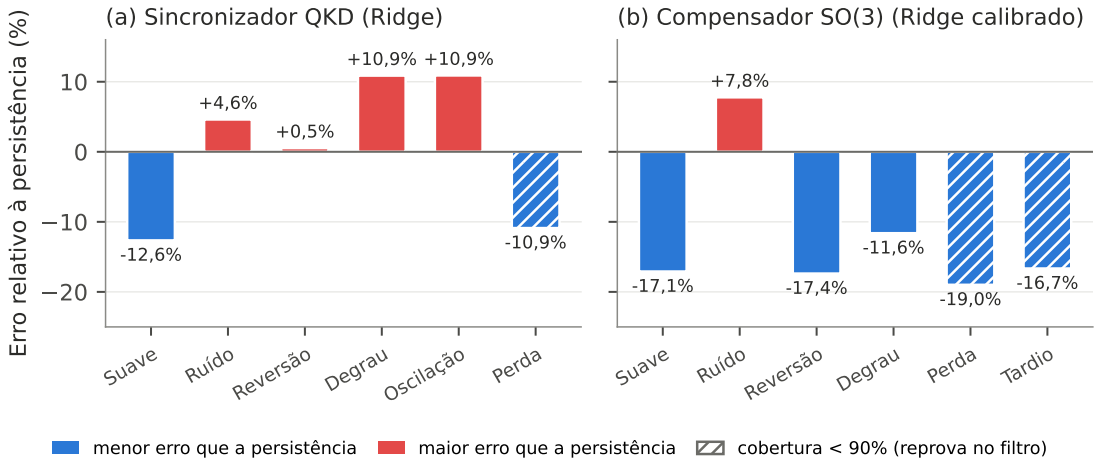


Figura 4. Erro de previsão relativo à persistência por cenário (negativo: modelo melhor). (a) Sincronizador, MAE do *offset* a +2 s; (b) compensador Ridge do regime calibrado, erro angular a +40 ms. Barras hachuradas reprovaram no critério de cobertura.

A Figura 4 resume as duas campanhas. O sincronizador atendeu ao critério apenas no cenário suave, com MAE 12,6% menor que a persistência. Com ruído independente, degrau e oscilação rápida, foi 4,6%, 10,9% e 10,9% pior; na reversão de deriva, empatou em média (5 vitórias em 10). Com perda de pacotes, o erro nos pares disponíveis foi 10,9% menor, mas a cobertura caiu para 80,7%.

O compensador Ridge atendeu ao critério em 6 dos 24 grupos: nos dois regimes, nos cenários suave, reversão térmica e degrau, com reduções de erro entre 11,6% e 17,4% frente à persistência no regime calibrado e vitória em todas as sementes. Com ruído na rotação, o Ridge calibrado foi 7,8% pior que a persistência. Com perda de pacotes ou resultados tardios, venceu nos pares disponíveis, mas a cobertura de 73,3% reprovou todos os *checkpoints*. O MLP perdeu para os dois *baselines* em todas as sementes e cenários (0 de 120 vitórias contra cada um) nesta família artificial.

9.3. Compensador em laço fechado

[PENDENTE: Tabela e texto da campanha em laço fechado: ângulo residual médio e QBER de desalinhamento para Ridge (dois regimes), sem compensação, persistência

e velocidade angular constante; diferença pareada e p de Holm por cenário.]

10. Discussão e Limitações

Os resultados mostram por que a comparação obrigatória com *baselines* é necessária. No estudo preliminar, o modelo com menor MAE foi o de pior utilidade. Nas campanhas *shadow*, o mesmo sincronizador que melhorava a persistência em sinal suave piorava com ruído ou mudanças abruptas, e a arquitetura mais expressiva (MLP) foi sistematicamente pior que a regressão linear. Uma plataforma que apenas executasse os modelos teria adotado esses componentes sem perceber; no ORION-Q, eles permanecem desligados, visíveis e com a evidência registrada.

As limitações são explícitas. Todos os resultados de controle são simulados, e os produtores artificiais formam uma família conhecida, não um teste cego. Os modelos foram treinados no SeQUeNCe, e as entradas geradas no ORION-Q, em especial as de roteamento, não reproduzem o domínio original. Os critérios das campanhas *shadow* são descritivos, sem teste de significância. Hashes comprovam identidade de arquivos, não validade científica ou autoria, e a aprovação no fluxo de ativação não autentica o operador. A latência de inferência medida inviabiliza decisões por par em memórias com T_2 da ordem de dezenas de microssegundos. Por fim, a hipótese de que a telemetria WDM prevê um alvo quântico físico futuro continua sem teste, por falta de dados pareados.

11. Conclusão e Trabalhos Futuros

Este trabalho apresentou o ORION-Q, uma plataforma de controle para redes quânticas simuladas que integra modelos de aprendizado de máquina como componentes opcionais, verificados e comparados a *baselines*. A plataforma admite cinco componentes (dez configurações) com identidade fixada e leitura segura, bloqueia um sexto que dependeria de desserialização insegura, reproduz suas saídas de referência, avalia-os em modo *shadow* e oferece um fluxo de ativação auditável e reversível. O estudo preliminar com telemetria WDM mostrou que menor erro de previsão não garante melhores decisões e que a persistência é um adversário difícil; as campanhas *shadow* confirmaram essa lição, com ganho consistente apenas do compensador Ridge em três de seis cenários. **[PENDENTE: conclusão do laço fechado]**

Como trabalhos futuros, destacam-se: estender a avaliação em laço fechado ao alocador e ao roteamento, este último por meio de um adaptador para o SeQUeNCe que devolva os modelos ao seu domínio de treino; obter uma exportação segura do detector; buscar ou produzir um conjunto de dados que combine telemetria WDM e alvo quântico medidos no mesmo enlace; executar em *hardware* quântico real um experimento de referência com pares de Bell; e reduzir a latência de inferência com aceleração dedicada.

Referências

Azuma, K., Economou, S. E., Elkouss, D., Hilaire, P., Jiang, L., Lo, H.-K., and Tzitrin, I. (2023). Quantum repeaters: From quantum networks to the quantum internet. *Reviews of Modern Physics*, 95(4):045006.

Bennett, C. H. and Brassard, G. (1984). Quantum cryptography: Public key distribution and coin tossing. In *Proceedings of the IEEE International Conference on Computers, Systems and Signal Processing*, pages 175–179, Bangalore.

Bennett, C. H., Brassard, G., Popescu, S., Schumacher, B., Smolin, J. A., and Wootters, W. K. (1996). Purification of noisy entanglement and faithful teleportation via noisy channels. *Physical Review Letters*, 76(5):722–725.

Briegel, H.-J., Dür, W., Cirac, J. I., and Zoller, P. (1998). Quantum repeaters: The role of imperfect local operations in quantum communication. *Physical Review Letters*, 81(26):5932–5935.

Coopmans, T., Knegjens, R., Dahlberg, A., et al. (2021). NetSquid, a NETwork Simulator for QUantum Information using Discrete events. *Communications Physics*, 4:164.

Dür, W., Briegel, H.-J., Cirac, J. I., and Zoller, P. (1999). Quantum repeaters based on entanglement purification. *Physical Review A*, 59(1):169–181.

Eraerds, P., Walenta, N., Legré, M., Gisin, N., and Zbinden, H. (2010). Quantum key distribution and 1 Gbps data encryption over a single fibre. *New Journal of Physics*, 12(6):063027.

Hochreiter, S. and Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8):1735–1780.

Hoerl, A. E. and Kennard, R. W. (1970). Ridge regression: Biased estimation for nonorthogonal problems. *Technometrics*, 12(1):55–67.

Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2):65–70.

Javadi-Abhari, A., Treinish, M., Krsulich, K., et al. (2024). Quantum computing with Qiskit. arXiv:2405.08810.

Kimble, H. J. (2008). The quantum internet. *Nature*, 453:1023–1030.

Kozlowski, W., Wehner, S., Van Meter, R., Rijsman, B., Cacciapuoti, A. S., Caleffi, M., and Nagayama, S. (2023). Architectural principles for a quantum internet. RFC 9340, Internet Research Task Force.

Krutyanskiy, V., Canteri, M., Meraner, M., Bate, J., Krcmarsky, V., Schupp, J., Sangouard, N., and Lanyon, B. P. (2023). Telecom-wavelength quantum repeater node based on a trapped-ion processor. *Physical Review Letters*, 130(21):213601.

Le, L. and Nguyen, T. N. (2022). Entanglement routing for quantum networks: A deep reinforcement learning approach. In *Proceedings of the IEEE International Conference on Communications (ICC)*.

Lo, H.-K., Ma, X., and Chen, K. (2005). Decoy state quantum key distribution. *Physical Review Letters*, 94(23):230504.

Nielsen, M. A. and Chuang, I. L. (2010). *Quantum Computation and Quantum Information*. Cambridge University Press, 10th anniversary edition.

Paszke, A., Gross, S., Massa, F., et al. (2019). PyTorch: An imperative style, high-performance deep learning library. In *Advances in Neural Information Processing*

Systems 32, pages 8024–8035.

Patel, K. A., Dynes, J. F., et al. (2012). Coexistence of high-bit-rate quantum key distribution and data on optical fiber. *Physical Review X*, 2(4):041010.

Preskill, J. (2018). Quantum computing in the NISQ era and beyond. *Quantum*, 2:79.

Schuirmann, D. J. (1987). A comparison of the two one-sided tests procedure and the power approach for assessing the equivalence of average bioavailability. *Journal of Pharmacokinetics and Biopharmaceutics*, 15(6):657–680.

Sutton, R. S. and Barto, A. G. (2018). *Reinforcement Learning: An Introduction*. MIT Press, 2nd edition.

Thomas, J. M. et al. (2023). Designing noise-robust quantum networks coexisting in the classical fiber infrastructure. *Optics Express*. arXiv:2304.09076.

Uhlenbeck, G. E. and Ornstein, L. S. (1930). On the theory of the Brownian motion. *Physical Review*, 36(5):823–841.

Wehner, S., Elkouss, D., and Hanson, R. (2018). Quantum internet: A vision for the road ahead. *Science*, 362(6412):eaam9288.

Wilson, E. B. (1927). Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, 22(158):209–212.

Wu, X., Kolar, A., Chung, J., Jin, D., Zhong, T., Kettimuthu, R., and Suchara, M. (2021). SeQUeNCe: a customizable discrete-event simulator of quantum networks. *Quantum Science and Technology*, 6(4):045027.

Xavier, G. B. et al. (2008). Full polarization control for fiber optical quantum communication systems using polarization encoding. *Optics Express*, 16(3):1867–1873.