APRENDIZADO DE MÁQUINA SOBRE OBSERVÁVEIS PÚBLICOS DE QKD: CLASSIFICAÇÃO DE ATAQUES, OTIMIZAÇÃO DA TAXA DE CHAVE E SINCRONISMO EM ENLACES COM *DECOY STATES*

Alexandre O. S. Santos[1,2]

[1]Quantum Industrial Innovation - QuIIN
Senai CIMATEC – Salvador, BA – Brazil

[2]Latin America Quantum Computing Center - LAQCC
Senai CIMATEC – Salvador, BA – Brazil

alexandreoliversan1@gmail.com, alexandre.ssantos@fbter.org.br

Abstract. *A deployed decoy-state QKD link monitors itself with a single statistic: the quantum bit error rate (QBER). That test is sound and operationally weak. It fires late, it fires for the weather, and it is blind to every attack that does not disturb the error rate. This work develops a classical machine-learning layer that consumes only the observables the two ends already publish — gains and error rates per intensity, the vacuum count, the decoy bounds — plus a cable thermometer. Attacks are modelled as modifications of the per-photon-number yields, so that what Bob observes is derived rather than asserted, and an attack with no physical signature acquires none in the dataset. On 90,720 settling periods of simulated sessions, a QBER threshold calibrated to a 1% false-alarm budget detects one of four attacks; a gradient-boosting classifier over the same public record reaches a macro F1 of 0.830 and separates eavesdropping from thermal drift. Two further controllers share the same physics: an advantage-actor-critic agent that tunes the transmitter intensities and clock, raising the provable secret key rate by 8.8% to 18.9% over a commissioning baseline across 25–80 km, and a timing predictor that keeps the detector gate aligned against the thermal drift of the propagation delay. The evaluation is deliberately adverse: attacks ramp in, work in bursts, and 40% of them run during a simultaneous thermal excursion. The central operational finding is that precision under a realistic prior is governed by the decision rate, not by the model — at a one-second settling period the best detector yields 0.22 precision, and at five seconds, with a calibrated decision threshold, it reaches 1.00 at the cost of detection delay. Against 575 days of a deployed link of the Cambridge Quantum Network, a QBER threshold calibrated at commissioning to a 1% budget fires on 16.5% of benign days, the measured cost of one point of QBER agrees with the model's key-rate physics to within 6%, and the coexistence penalty has the predicted Raman form.*

Keywords: *Quantum Key Distribution, Decoy States, Attack Detection, Reinforcement Learning, Secret Key Rate, Time Synchronisation, Field Validation.*

Resumo. *Um enlace de QKD com* decoy states *implantado monitora a si mesmo por uma única estatística: a taxa de erro quântica (QBER). O teste é correto e operacionalmente fraco — dispara tarde, dispara por causa do clima e é cego a todo ataque que não perturba a taxa de erro. Este trabalho desenvolve uma camada clássica de aprendizado de máquina que consome apenas os observáveis que as duas pontas já publicam — ganhos e taxas de erro por intensidade, contagem de vácuo e as cotas de* decoy *— somados a um termômetro no cabo. Os ataques são modelados como modificações dos* yields *por número de fótons, de modo que o que Bob observa é derivado e não postulado, e um ataque sem assinatura física não ganha assinatura no conjunto de dados. Em 90.720 períodos de acerto de sessões simuladas, um limiar de QBER calibrado para 1% de alarme falso detecta um dos quatro ataques; um classificador por* gradient boosting *sobre o mesmo registro público atinge F1 macro de 0,830 e separa espionagem de deriva térmica. Dois controladores adicionais compartilham a mesma física: um agente ator-crítico que ajusta intensidades e* clock *do transmissor, elevando a taxa de chave secreta provável entre 8,8% e 18,9% sobre a linha de base de comissionamento em vãos de 25 a 80 km, e um preditor temporal que mantém a janela do detector alinhada contra a deriva térmica do atraso de propagação. A avaliação é deliberadamente adversa: ataques entram em rampa, operam em rajadas e 40% deles ocorrem durante excursão térmica simultânea. O achado operacional central é que a precisão sob prior realista é governada pela taxa de decisão, não pelo modelo — com período de acerto de um segundo o melhor detector atinge precisão de 0,22, e com cinco segundos, sob limiar de decisão calibrado, atinge 1,00 ao custo de atraso de detecção. Confrontado com 575 dias de um enlace implantado da rede quântica de Cambridge, um limiar de QBER calibrado no comissionamento para 1% dispara em 16,5% dos dias benignos, o custo medido de um ponto de QBER concorda com a física de taxa de chave do modelo dentro de 6%, e a penalidade de coexistência tem a forma Raman prevista.*

Palavras-chave: *Distribuição Quântica de Chaves, Decoy States, Detecção de Ataques, Aprendizado por Reforço, Taxa de Chave Secreta, Sincronismo Temporal, Validação em Campo.*

1 Introdução

A Distribuição Quântica de Chaves (QKD) transporta sua segurança de uma hipótese computacional para uma lei física: qualquer tentativa de leitura de um estado quântico desconhecido o perturba [Bennett and Brassard 1984, Gisin et al. 2002]. A construção real, porém, não usa fótons únicos. Transmissores implantados usam laser atenuado,

cujo número de fótons por pulso é uma variável de Poisson, e uma fração dos pulsos carrega dois fótons ou mais. Sobre essa fração existe um ataque que não perturba nada: a separação por número de fótons (PNS), na qual o espião retém um fóton dos pulsos multifotônicos e encaminha o restante [Brassard et al. 2000]. Contra ele, contar erros é inútil.

A resposta consolidada são os *decoy states* [Hwang 2003, Lo et al. 2005, Ma et al. 2005]: Alice varia a intensidade dos pulsos ao acaso, e como Eva não sabe em qual intensidade cada pulso foi enviado, o que ela faz a pulsos de n fótons ela faz a todos igualmente. Os *yields* Y_n resultantes são propriedade do canal, não da intensidade, e medir o ganho em várias intensidades restringe o rendimento de fóton único, que é a única parte do sinal capaz de produzir chave secreta [Gottesman et al. 2004].

O que um enlace implantado faz com essa informação, contudo, é notavelmente pobre: monitora o QBER e interrompe a produção de chave quando ele cruza o limiar de segurança. Esse detector é correto e operacionalmente fraco em três sentidos. Dispara tarde, porque um ataque fraco precisa acumular erro para ser visto. Dispara por causa do ambiente, porque deriva de polarização em fibra implantada produz a mesma subida de erro [Czegledi et al. 2016, Ramaswamy et al. 2026]. E quando dispara, não diz o que fazer: uma curvatura na fibra exige um técnico, um *intercept-and-resend* exige derrubar o enlace, e uma tarde quente não exige nada.

Este trabalho investiga a hipótese de que a distinção entre essas causas é recuperável por inferência clássica sobre o registro que as duas pontas já publicam, sem instrumentação adicional além de um termômetro no cabo. A contribuição não é apenas um classificador: é uma camada de controle com três funções — classificação de eventos, otimização dos parâmetros do transmissor por aprendizado por reforço e predição da deriva temporal do atraso de propagação — construída sobre uma única formulação física, e avaliada sob um protocolo projetado para não inflar os próprios resultados.

2 Justificativa

A literatura de aprendizado de máquina aplicada a QKD reporta rotineiramente acurácias acima de 95% em detecção de ataques [Mao et al. 2020, Xu et al. 2024]. Três decisões metodológicas explicam boa parte desses números e comprometem sua transposição para operação:

1. **Ataques postulados, não derivados.** Quando um ataque é modelado como um deslocamento imposto ao QBER, o classificador aprende a constante que o autor digitou. A alternativa é modelar a ação do espião sobre os Y_n e deixar os observáveis emergirem, o que impede que um ataque sem assinatura física adquira uma no conjunto de dados.

2. **Ataques em degrau, isolados.** Um espião que sabe que o enlace é monitorado não entra em vigor pleno num instante. E o caso adverso real não é o ataque limpo: é

o ataque que começa durante uma excursão térmica, quando a explicação inocente para o erro subindo já é verdadeira.

3. **Classes balanceadas e acurácia como métrica.** Em um enlace real, ataque é raro. Uma taxa de alarme falso de 1% por período parece pequena e, com período de acerto de um segundo, equivale a 36 chamados por hora.

Além da detecção, dois problemas de controle compartilham a mesma física e são tratados aqui. O primeiro é a escolha dos parâmetros do transmissor: a intensidade do sinal, a do *decoy* fraco, a divisão dos pulsos e a taxa de repetição. O ponto ótimo se move com a perda do vão, com o desalinhamento óptico residual e com a proximidade da saturação dos detectores, e sistemas implantados o fixam uma vez, no comissionamento [Wang and Lo 2019]. O segundo é o sincronismo: a sílica muda de índice e de comprimento com a temperatura, o que desloca o instante de chegada do pulso, e uma janela de detecção de centenas de picossegundos não sobrevive a um kelvin sem rastreamento.

3 Objetivos

3.1 Objetivo Geral

Desenvolver e avaliar uma camada de aprendizado de máquina para enlaces de QKD com *decoy states* que, usando exclusivamente observáveis públicos e sensores ambientais disponíveis, classifique a causa de degradações no enlace, otimize os parâmetros do transmissor sob condições variáveis e mantenha o sincronismo temporal do receptor, sob um protocolo de avaliação que reporte métricas operacionais em vez de acurácia balanceada.

3.2 Objetivos Específicos

- **Formular a física observável:** implementar o protocolo BB84 com *decoy states* em torno dos *yields* por número de fótons, com as cotas de vácuo mais *decoy* fraco [Ma et al. 2005] e a taxa GLLP [Gottesman et al. 2004], incluindo amostragem binomial de blocos finitos.
- **Modelar ataques como modificação de canal:** expressar *intercept-and-resend*, PNS, cegamento de detector e divisor de feixe como transformações dos Y_n, preservando os invariantes que tornam cada um difícil.
- **Construir um gerador adverso de sessões:** episódios com linha de base de comissionamento, deriva de polarização, perfis temporais de ataque (degrau, rampa e intermitente) e co-ocorrência com excursões térmicas.
- **Avaliar classificadores sob métricas de operador:** recall por classe, alarmes falsos por hora e precisão sob prior realista, com separação por episódio e um controle negativo fisicamente indetectável.

- **Treinar um agente de taxa de chave:** ator-crítico com vantagem generalizada [Mnih et al. 2016, Schulman et al. 2016] recompensado pela chave *provável* sobre contagens finitas.
- **Predizer a deriva temporal:** modelar o atraso de propagação sob variação térmica e avaliar rastreadores em laço fechado pela eficiência de detecção e pela taxa de chave resultante.

4 Trabalhos Relacionados e Estado da Arte

4.1 Predição de parâmetros por aprendizado de máquina

[Wang and Lo 2019] demonstram que uma rede neural rasa prevê os parâmetros ótimos de protocolos de *decoy state* com erro desprezível e custo computacional compatível com operação embarcada, substituindo a otimização local que normalmente roda em nuvem. O trabalho estabelece a viabilidade da inferência clássica no laço de controle, mas assume canal conhecido: a predição é uma função dos parâmetros do enlace, não das observações ruidosas do último bloco. O presente trabalho remove essa hipótese, tratando a escolha como problema de controle sob observação parcial.

4.2 Detecção de ataques por aprendizado de máquina

Em variáveis contínuas, [Mao et al. 2020] aplicam aprendizado supervisionado a ataques de calibração e LO, e [Xu et al. 2024] reportam identificação automática de imperfeições e ataques com acurácia de 98%. Ambos os trabalhos tratam classes balanceadas e ataques de intensidade fixa. A lacuna que este trabalho endereça não é de arquitetura — é de protocolo experimental: nenhum dos dois reporta alarmes falsos por hora, precisão sob prior realista, comportamento sob ataque gradual ou intermitente, nem inclui uma classe de controle que a física garante ser indetectável.

4.3 Ataques de implementação

O cegamento de detectores por iluminação intensa [Lydersen et al. 2010] e o ataque de deslocamento temporal [Zhao et al. 2008] são exemplares porque não atacam o protocolo, e sim o equipamento: ambos produzem chave aparentemente segura enquanto entregam a chave ao espião. Revisões recentes do campo [Scarani et al. 2009, Diamanti et al. 2016, Xu et al. 2020, Pirandola et al. 2020] convergem no ponto de que a segurança prática de QKD é hoje um problema de caracterização de dispositivo, não de prova matemática — que é precisamente a razão de existir um monitor que distinga ataque de falha de hardware.

4.4 Deriva de polarização e dados de campo

Medidas em fibra implantada estabelecem o regime a ser reproduzido: [Czegledi et al. 2016] caracterizam 127 km de fibra enterrada ao longo de 36 dias e ajustam uma largura de linha de polarização de 60–80 nHz; [Ramaswamy et al. 2026] medem, em 15 km de cabo híbrido aéreo/enterrado ao longo de 11 meses, densidade espectral do tipo *flicker* com expoente $\beta = 1{,}0 \pm 0{,}2$; e [Shi et al. 2026] observam, em 62 km majoritariamente aéreos, excursões de dezenas de graus em segundos durante o dia. Em enlaces de QKD em produção, [Dynes et al. 2019] reportam 580 dias de operação de três enlaces metropolitanos em Cambridge, com os dados das figuras depositados sob licença aberta — e usados na Seção 10 deste trabalho —, e [Martin et al. 2024] documentam uma rede metropolitana heterogênea com QBER e taxa de chave monitorados por semestres.

5 Fundamentação Teórica

5.1 Ganho, erro e *yields* por número de fótons

Seja Y_n a probabilidade de que Bob registre um clique dado que Alice enviou um pulso de n fótons, e e_n a probabilidade de que esse clique esteja errado. O ganho observado em uma intensidade μ é a mistura de Poisson

$$Q_\mu = \sum_{n=0}^{\infty} \frac{\mu^n e^{-\mu}}{n!} Y_n, \qquad E_\mu Q_\mu = \sum_{n=0}^{\infty} \frac{\mu^n e^{-\mu}}{n!} Y_n e_n. \tag{1}$$

Para o canal honesto com transmitância η, contagem de escuro Y_0 e erro de desalinhamento óptico e_d, valem $\eta_n = 1-(1-\eta)^n$, $Y_n = Y_0 + \eta_n - Y_0\eta_n$ e $e_n = (e_0 Y_0 + e_d \eta_n)/Y_n$, com $e_0 = 1/2$ por física — um clique sem fóton por trás não guarda correlação com o bit enviado.

5.2 Cotas de *decoy* e taxa de chave

Com o protocolo de vácuo mais *decoy* fraco, $\nu < \mu$, as cotas de [Ma et al. 2005] fornecem

$$Y_1 \geq Y_1^L = \frac{\mu}{\mu\nu - \nu^2}\left(Q_\nu e^{\nu} - Q_\mu e^{\mu}\frac{\nu^2}{\mu^2} - \frac{\mu^2-\nu^2}{\mu^2} Y_0 \right), \qquad e_1 \leq e_1^U = \frac{E_\nu Q_\nu e^{\nu} - e_0 Y_0}{Y_1^L \nu}. \tag{2}$$

A taxa de chave secreta segue a formulação GLLP [Gottesman et al. 2004],

$$R \;\geq\; q\left[Q_1^L\big(1 - h(e_1^U)\big) - f\, Q_\mu\, h(E_\mu) \right], \qquad Q_1^L = Y_1^L \mu\, e^{-\mu}, \tag{3}$$

com $h(\cdot)$ a entropia binária, f a ineficiência da reconciliação e q o fator de *sifting*. Os efeitos de bloco finito seguem a análise composta de [Tomamichel et al. 2012], implementada para contraste com o limite assintótico.

5.3 Ataques como modificação dos *yields*

Cada ataque é implementado como uma transformação de (Y_n, e_n), e os observáveis são recalculados pelo mesmo caminho de código do canal honesto. A Tabela 1 resume os invariantes, e a Figura 1 mostra o ganho resultante em função da intensidade.

Tabela 1. Invariantes de cada ataque. O que não se move é o que torna o problema difícil.

Ataque	**Ação sobre o canal**	**Assinatura**
Intercept-and-resend	$e'_n = (1-q)e_n + q(\frac{1}{2}e_n + \frac{1}{4})$	só o erro; ganho intacto
PNS	$Y'_1 = (1-b)Y_1$; $Y_{n\geq 2}$ compensado	Q_μ e E_μ intactos; Q_ν cai
Cegamento de detector	$Y'_{n\geq 1} \geq p_{\text{forçado}}$; $Y'_0 = Y_0 + \ell$	ganho acima da perda; vácuo clica
Divisor de feixe	identidade	nenhuma, por construção

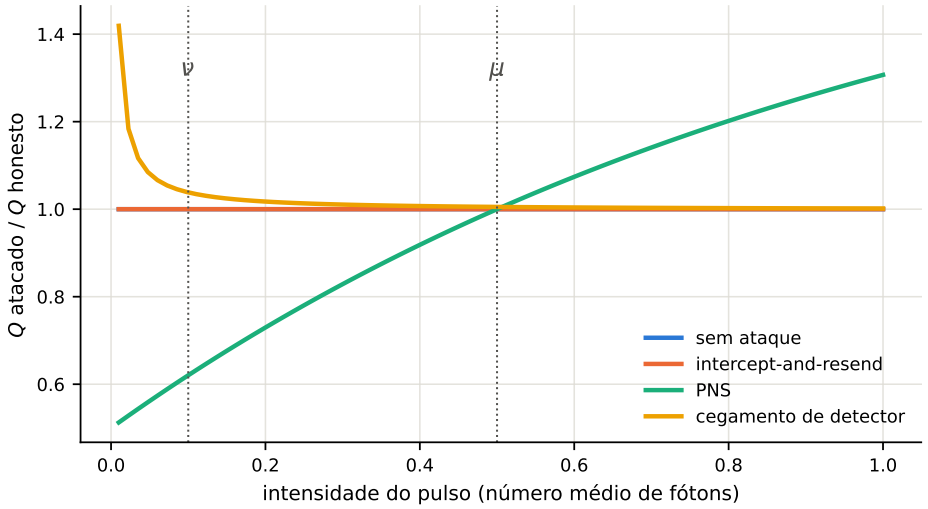


Figura 1. Ganho sob ataque dividido pelo ganho honesto, a 50 km, calculado diretamente da física. O PNS mantém o ganho exatamente onde estava na intensidade do sinal (μ) e não consegue mantê-lo no *decoy* fraco (ν), onde quase todo pulso é de fóton único; o intercept-and-resend não move o ganho em nenhuma intensidade; o cegamento empurra o ganho acima do que a perda do canal permite.

5.4 Limites do receptor

Três correções do próprio receptor entram no modelo, porque são o que impede que aumentar a taxa de repetição seja gratuito. O tempo morto τ_d escala os *yields* por $1/(1 + r\tau_d)$, com r a taxa bruta de cliques; o *afterpulsing* adiciona cliques descorrelacionados proporcionais à taxa de cliques; e a dispersão cromática alarga o pulso, de modo que, no período de *slot* $T = 1/f$, a fração de fótons atribuída ao *slot* vizinho produz erro de intersímbolo $e_{\text{ISI}} = \frac{1}{2}\operatorname{erfc}\left(T/2\sqrt{2}\sigma\right)$. O teto do *clock* pertence, portanto, ao vão e não ao receptor.

6 Metodologia e Arquitetura de Simulação

6.1 Sessões, e não fórmulas

A unidade de simulação é um episódio: um enlace operando por 10 minutos, acertando contas a cada segundo — 10^9 pulsos por período a 1 GHz —, com a fibra derivando abaixo e um evento começando em um instante não anunciado. O primeiro minuto é garantidamente livre de eventos e funciona como a calibração de comissionamento que todo enlace implantado possui. A deriva de polarização usa o modelo térmico mais vibração mais saltos discretos calibrado em [Czegledi et al. 2016, Ramaswamy et al. 2026], e o resíduo que um compensador em malha fechada não remove entra como desalinhamento óptico adicional. O comprimento do vão é sorteado entre 20 e 70 km por episódio.

6.2 Perfis adversos

Todo ataque sorteia um perfil temporal — degrau (40%), rampa linear (35%) ou intermitente (25%) — e 40% dos episódios de ataque carregam uma excursão térmica simultânea. A severidade é escalada continuamente por um fator $s(t) \in [0,1]$ que multiplica tudo o que o evento faz, de modo que um ataque em rampa realmente intercepta uma fração crescente do tráfego. O contrato verificado em teste é que $s = 0$ é indistinguível de canal honesto.

6.3 Atributos

Dezessete atributos são calculados por período, todos relativos à linha de base do próprio episódio. A escolha não é conveniência: um ganho absoluto é sobretudo uma afirmação sobre o comprimento do vão, e as grandezas informativas são razões que não deveriam ter mudado. Entram razões logarítmicas de ganho de sinal, de *decoy* e de vácuo; deslocamentos de taxa de erro; razões das cotas Y_1^L e e_1^U; ganho medido contra o previsto pela calibração; e três atributos de janela móvel — tendência do erro, volatilidade e a correlação entre o erro e $|dT/dt|$. Esse último é o discriminador térmico: a taxa de deriva da birrefringência é acoplada à *variação* de temperatura, então uma excursão térmica produz erro que sobe enquanto a temperatura se move e assenta quando ela para — correlação que o espião não possui. As colunas de verdade de referência (desalinhamento real, transmitância real, Y_1 real) são explicitamente proibidas no construtor de atributos.

6.4 Protocolo de avaliação

A separação treino/teste é **por episódio**, não por linha: linhas do mesmo episódio compartilham calibração, comprimento de vão e realização de deriva. Setenta por cento dos episódios vão para treino; destes, 20% são reservados fora do ajuste para calibrar o limiar de decisão. O divisor de feixe é gerado e pontuado, mas não treinado: uma classe cujos

atributos são idênticos aos de outra ensina o modelo apenas a dividir ruído. As métricas reportadas são recall por classe, alarmes falsos por hora de operação saudável (contando *inícios* de alarme) e precisão sob prior de 1%; acurácia é deliberadamente omitida.

7 Modelos de Inferência e Controle

7.1 Detectores

Quatro famílias são comparadas sobre a mesma matriz de atributos: um limiar de QBER calibrado por orçamento de alarme falso, que representa o que sistemas implantados fazem hoje; *random forest* [Breiman 2001]; máquina de vetores de suporte com núcleo RBF [Cortes and Vapnik 1995]; e *gradient boosting* histogramático [Friedman 2001, Ke et al. 2017], implementados sobre *scikit-learn* [Pedregosa et al. 2011]. Duas camadas operacionais são acrescentadas ao melhor modelo: um limiar de decisão sobre a massa de probabilidade atribuída às classes de ataque, calibrado para um orçamento de alarme falso em episódios não vistos, e uma histerese que exige persistência de três períodos antes de contar um alarme.

7.2 Agente de taxa de chave

O ajuste do transmissor é formulado como processo de decisão sequencial [Sutton and Barto 2018]. O estado é um vetor de dezesseis entradas contendo os observáveis do período anterior relativos à calibração, a configuração corrente e — decisivo — duas entradas *absolutas* de regime de perda. As nove ações são ajustes multiplicativos em μ, ν e *clock*, e aditivos na fração de pulsos de sinal. A recompensa é a chave que se consegue *provar* naquele período, calculada pelas cotas de *decoy* sobre contagens binomiais finitas, e não a taxa assintótica. O treinamento usa ator-crítico com vantagem generalizada [Mnih et al. 2016, Schulman et al. 2016] e otimizador Adam [Kingma and Ba 2015], com redes implementadas em *numpy* [Harris et al. 2020] e retropropagação escrita manualmente, verificada contra diferenças finitas.

7.3 Sincronismo temporal

O coeficiente termo-óptico da sílica implica aproximadamente 40 ps de atraso por quilômetro por kelvin; em 50 km, um kelvin são dois nanossegundos, dez vezes a janela típica de um detector com porta. O modelo compõe essa deriva com o resíduo de um *clock* recuperado do canal clássico. Quatro preditores são comparados em laço fechado com latência: nenhuma correção, recalibração periódica com tempo morto, filtro alfa-beta, e regressão *ridge* sobre janela de estimativas mais termômetro. A pontuação não é o RMS do desalinhamento, e sim a eficiência de detecção e a taxa de chave que sobrevivem.

7.4 Compensador temporal causal

Para a compensação de polarização, compara-se a rede densa sobre janela achatada com uma pilha de convoluções causais dilatadas [van den Oord et al. 2016, Bai et al. 2018], alternativa às redes recorrentes [Hochreiter and Schmidhuber 1997] com três vantagens específicas ao laço: a causalidade é estrutural e não aprendida, o campo receptivo é um parâmetro de projeto, e a inferência é uma multiplicação matricial em vez de um laço sobre o tempo.

8 Avaliação Experimental: Detecção

O conjunto compreende 168 episódios (24 por classe), 100.800 linhas e 90.720 períodos com atributos; 64.260 linhas de treino, das quais 44.280 para ajuste e 10.800 para calibração de limiar, e 22.680 períodos pontuados em teste.

Tabela 2. Recall por classe em episódios retidos. O limiar de QBER responde apenas "ataque" ou "normal" e por isso zera a coluna de tipo.

Classe	Limiar QBER	Random forest	SVM (RBF)	Boos- ting	Boosting+ lim.+hist.
normal	0,993	0,948	0,924	0,938	**0,968**
deriva térmica	0,000	0,864	0,651	**0,875**	0,863
evento de perda	0,000	**1,000**	0,950	**1,000**	0,992
intercept-and-resend	0,000	**0,636**	0,602	0,597	0,513
PNS	0,000	**0,749**	0,416	0,745	0,709
cegamento de detector	0,000	0,840	0,831	**0,908**	0,792

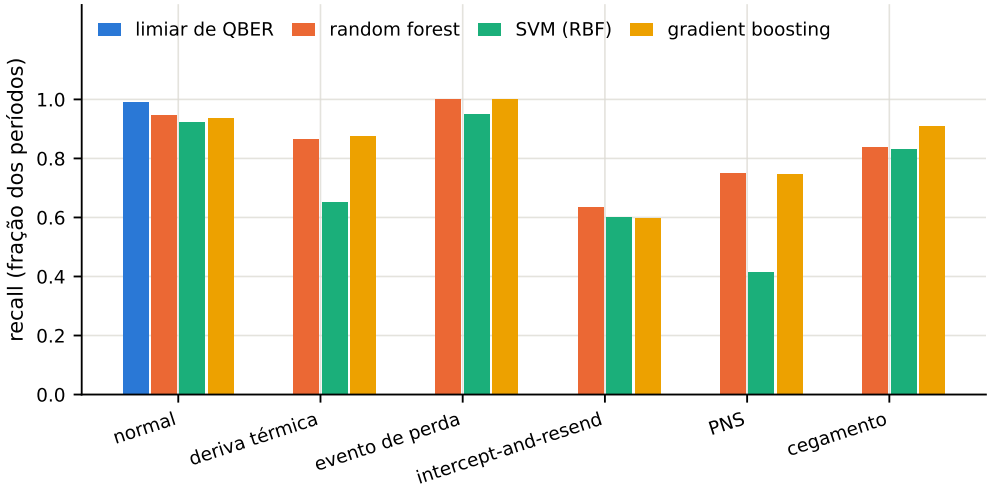


Figura 2. Recall por classe. O limiar de QBER está calibrado para 1% de alarme falso no conjunto de treino — é o que um operador faria com ele, e não um espantalho.

O limiar de QBER, mesmo na versão binária, detecta 27% dos períodos de intercept-and-resend, 4% dos de PNS, 11% dos de cegamento e 3% dos de evento de perda. A assimetria é consequência da física: nenhum dos três últimos move a taxa de erro. A Tabela 3 reporta as métricas que decidem implantabilidade.

Tabela 3. Métricas operacionais, período de acerto de 1 s. "Alarmes/hora" conta inícios de alarme em períodos comprovadamente limpos.

Detector	F1 macro	Alarme falso	Alarmes/hora	Precisão a 1%
Limiar de QBER	0,128	0,0073	1,6	0,103
Random forest	**0,832**	0,0525	8,9	0,155
SVM (RBF)	0,702	0,0761	36,4	0,113
Gradient boosting	0,830	0,0618	14,9	0,135
Boosting + limiar de decisão	0,825	0,0373	11,0	0,200
Boosting + limiar + histerese	0,818	**0,0321**	**6,8**	**0,220**

8.1 Controle negativo

O divisor de feixe não deixa assinatura alguma, e a resposta correta em seus períodos é "normal". *Random forest* e *boosting* respondem isso em 91% deles, e o SVM em 83%: fronteiras suaves inventam ataque onde não há o que ver. Uma taxa de detecção acima do acaso nessa classe indicaria vazamento do gerador, e é por isso que ela é reportada separadamente e não incorporada à acurácia.

8.2 Qual física carrega a separação

Tabela 4. Ablações sobre a *random forest*. Cada linha remove um bloco de atributos.

Variante	F1 macro	Alarmes /hora	PNS	Deriva térmica	Interc.-resend
Completa	**0,832**	8,9	0,749	0,864	0,636
Sem termômetro	0,768	80,7	0,753	**0,425**	0,536
Sem observáveis de *decoy*	0,770	12,3	**0,400**	0,881	0,620
Só QBER e ganho	0,622	104,3	**0,098**	0,390	0,542

A Tabela 4 reproduz, como resultado de aprendizado, a afirmação de segurança do protocolo: sem os observáveis de *decoy*, o PNS deixa de ser separável de forma confiável, e com apenas QBER e ganho torna-se praticamente invisível. A remoção do termômetro derruba a deriva térmica pela metade e multiplica os alarmes falsos por nove, porque deriva térmica e intercept-and-resend produzem a mesma subida de QBER e se distinguem pela causa.

Tabela 5. Desempenho do *gradient boosting* restrito aos períodos com ataque em curso, por perfil temporal e por co-ocorrência térmica.

Caso	Períodos	Recall	Detectado como algo
Degrau	4.449	0,944	0,994
Rampa	2.678	0,778	0,970
Intermitente	1.811	0,562	0,834
Com excursão térmica simultânea	2.685	0,631	**1,000**
Sem excursão térmica	6.253	0,897	0,935

8.3 Casos adversos

O ataque intermitente é o mais penalizado, por razão mecânica: metade dos períodos rotulados como ataque são os intervalos entre rajadas, nos quais não há nada a observar. A co-ocorrência térmica produz o achado mais informativo — o ataque é *sempre* detectado como alguma coisa, mas o tipo correto cai de 0,897 para 0,631. A excursão térmica não esconde o ataque; ela rouba o rótulo. Para comparação, o mesmo pipeline sobre um gerador restrito a ataques em degrau isolados produz F1 macro de 0,93 e alarme falso de 1,4%: **o número mais alto mede um problema mais fácil**.

8.4 A taxa de decisão, e não o modelo

Tabela 6. Mesmo pipeline com período de acerto de 5 s (12 episódios por classe).

Detector	F1 macro	Alarme falso	Alarmes/hora	Precisão a 1%
Limiar de QBER	0,114	0,0181	0,5	0,012
Random forest	**0,760**	0,0798	5,0	0,103
Gradient boosting	0,747	0,0843	3,9	0,101
Boosting + limiar de decisão	0,718	0,0001	0,1	0,982
Boosting + limiar + histerese	0,694	**0,0000**	**0,0**	**1,000**

Com período de cinco segundos e limiar de decisão calibrado em episódios não vistos, o alarme falso vai praticamente a zero e a precisão sob prior realista passa de 0,22 para 1,00. O preço é atraso — dezenas de segundos em vez de um — e o tipo do intercept-and-resend fraco, que passa a ser reportado como deriva térmica ainda que o alarme suba. Trata-se de escolha de ponto de operação e não de melhoria: um enlace que precise reagir em segundos permanece no período curto e paga em chamados.

Registra-se uma armadilha metodológica encontrada nesse ponto. Calibrar o limiar de decisão sobre as mesmas linhas usadas no ajuste produz limiar nulo — o *boosting* praticamente não sinaliza períodos limpos que memorizou, embora sinalize 6% dos retidos — e o alarme falso *piora*. A calibração em 20% dos episódios de treino, fora do ajuste, é o que torna o mecanismo eficaz.

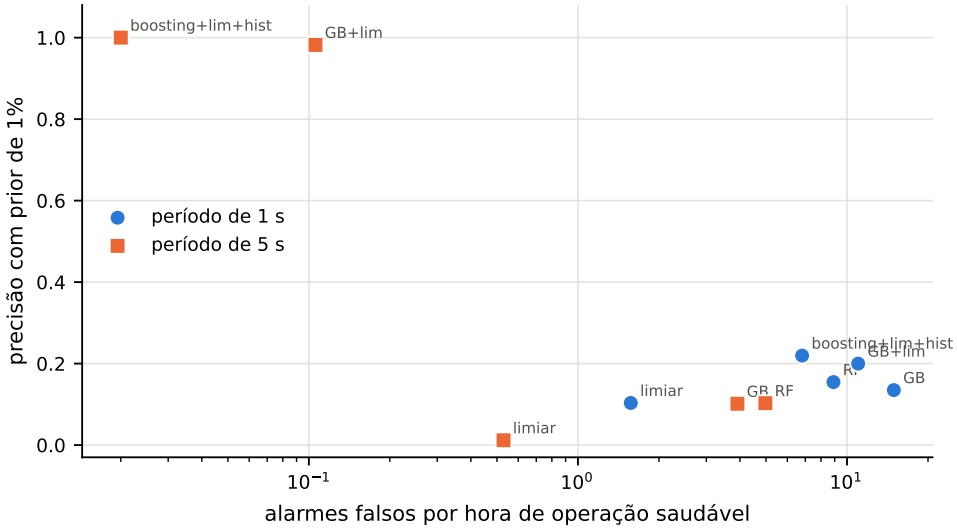


Figura 3. Alarmes falsos por hora contra precisão sob prior de 1%, nos dois períodos de acerto. O eixo horizontal é logarítmico. A mudança de regime não vem de trocar o modelo, e sim de decidir cinco vezes menos e com cinco vezes mais contagens por decisão.

9 Avaliação Experimental: Controle

9.1 Taxa de chave secreta

O agente generalista foi treinado sorteando o vão entre 25 e 80 km por episódio. A temperatura de amostragem foi escolhida em sementes de validação disjuntas do teste, resultando em $T = 0{,}25$; o valor difere do encontrado na literatura de políticas estocásticas porque, em vão longo, o ótimo é raso e a exploração custa mais do que encontra.

Tabela 7. Taxa de chave secreta provável, média de 24 episódios de teste por vão (desvio-padrão entre episódios entre parênteses), em Mbit/s.

Vão	Estático (comissionamento)	Agente	Oráculo	Ganho
25 km	3,180 (0,451)	**3,782** (0,506)	3,817 (0,584)	**+18,9%**
35 km	2,732 (0,425)	**3,092** (0,397)	3,059 (0,417)	+13,2%
50 km	1,899 (0,319)	**2,128** (0,312)	2,152 (0,353)	+12,1%
65 km	1,038 (0,169)	**1,138** (0,213)	1,220 (0,244)	+9,6%
80 km	0,489 (0,072)	**0,532** (0,113)	0,713 (0,107)	+8,8%

Até 50 km o agente recupera mais de 90% da lacuna entre a linha de base e o oráculo. Duas correções produziram esse resultado, e ambas merecem registro por serem diagnósticos, não ajustes. A primeira: com atributos exclusivamente relativos à calibração, o agente não distingue regimes — uma queda de 20% no ganho é idêntica em 25 e em 80 km, embora os dois regimes exijam movimentos opostos, pois em vão curto os detectores saturam e em vão longo a cota de fóton único passa fome. Duas entradas absolutas

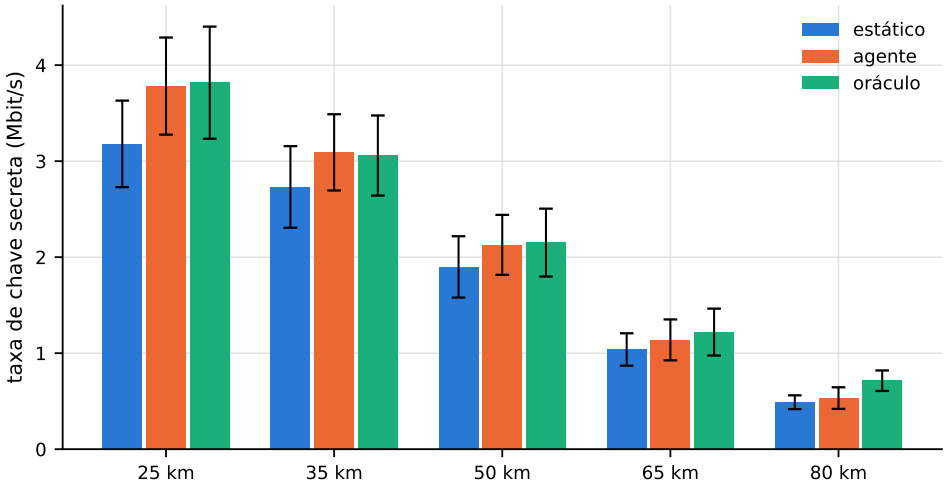


Figura 4. Taxa de chave por vão. O oráculo lê o canal verdadeiro e reotimiza a cada período; olha uma ação à frente e maximiza a taxa assintótica, sendo referência e não teto — em 35 km o agente o supera.

levaram o vão de 80 km de $-14{,}7\%$ a $+1{,}6\%$. A segunda: a varredura de temperatura de amostragem, que adicionou o restante.

O comportamento aprendido é fisicamente interpretável. Em vãos curtos o agente leva o *decoy* ao piso da faixa ($\nu \approx 0{,}011$ contra os 0,1 do comissionamento), como a fórmula assintótica prescreve; em 80 km ele o eleva a $\nu \approx 0{,}25$, que é exatamente onde a penalidade de estatística finita passa a dominar — e é também o único vão em que a margem sobre a linha de base é a menor.

9.2 Sincronismo temporal

Tabela 8. Taxa de chave a 50 km por sincronizador e largura de janela, em Mbit/s, média de 12 execuções de uma hora.

Escuro	Janela	Sem correção	Recalib. 60 s	Filtro alfa-beta	Ridge + termômetro
10 Hz	200 ps	0,136	1,001	1,464	**1,508**
	500 ps	0,309	1,631	1,958	**1,971**
	1000 ps	0,530	1,924	**2,007**	**2,007**
10^6 Hz	200 ps	0,000	0,429	0,948	**0,998**
	350 ps	0,000	0,536	1,064	**1,099**
	1000 ps	0,000	0,128	0,253	0,253

Três leituras importam mais que o ranqueamento. Primeira: um enlace calibrado e deixado sem rastreamento perde 85% da chave em uma hora com detector silencioso e toda ela com detector ruidoso — resultado que é o coeficiente termo-óptico da sílica, não aprendizado de máquina. Segunda: recalibrar periodicamente custa nos dois lados, pois a janela envelhece entre varreduras e a varredura interrompe o enlace; a 60 s de

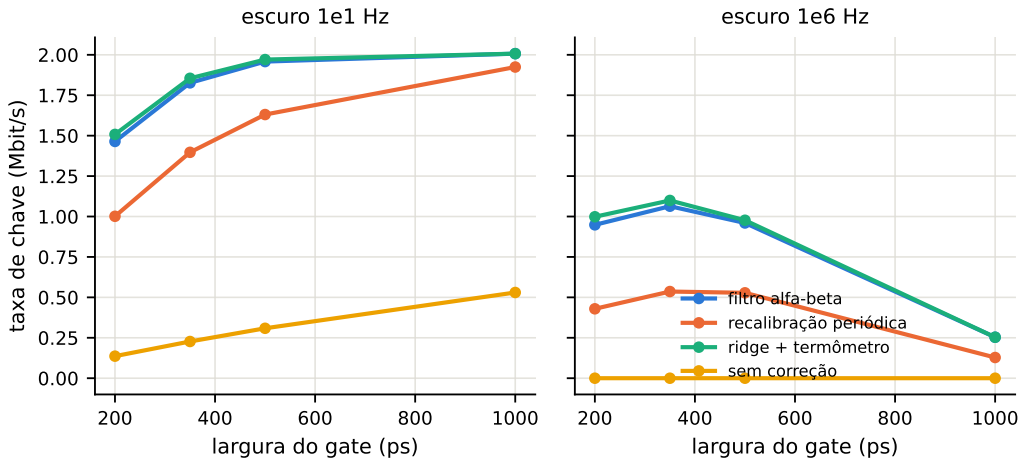


Figura 5. Taxa de chave contra largura da janela do detector, para dois regimes de contagem de escuro. Com detector supercondutor silencioso, alargar a janela é quase gratuito; com receptor ruidoso existe um ótimo interior, e sustentar uma janela estreita exige rastreamento de qualidade.

intervalo entrega 83% do rastreamento contínuo. Terceira: a margem do preditor aprendido é modesta e aparece onde deveria — janela estreita e detector ruidoso —, porque ele usa o termômetro e a componente térmica é proporcional à *variação* de temperatura, informação que um filtro alfa-beta sobre a série do atraso não pode inferir.

9.3 Compensador temporal causal

Tabela 9. Erro de validação por arquitetura, mesmas linhas e mesmo otimizador. O campo receptivo é aritmética, não hiperparâmetro.

Modelo	Campo receptivo	Parâmetros	MSE de validação
Rede densa (192, 192)	15	47.043	**3.438**
TCN 32 canais, dilatações (1, 2)	7	5.923	7.035
TCN 32 canais, dilatações (1,2,4)	15	9.027	3.583
TCN 48 canais, dilatações (1,2,4)	15	17.923	3.586
TCN 64 canais, dilatações (1,2,4)	15	29.891	3.592

Com duas camadas dilatadas a pilha alcança sete atrasos; um período da banda de vibração a 40 Hz corresponde a 12,5 passos de controle, de modo que sete atrasos não cobrem uma oscilação inteira, e o erro dobra. Com três camadas o campo chega a quinze, cobre o período, e o erro retorna ao patamar da rede densa. Capacidade adicional não altera o resultado. Em laço fechado, a rede densa entrega 55.145 bit/s de chave finita, a regressão *ridge* 54.722 e o TCN 54.636, contra 25.183 do filtro alfa-beta e 6.323 sem compensação. A conclusão honesta é que a convolução causal *iguala* a rede densa com um quinto dos parâmetros, e não a supera: o viés indutivo de equivariância temporal economiza capacidade, não erro.

10 Validação com Dados de Campo

Todos os resultados anteriores foram medidos contra o simulador deste trabalho. Esta seção confronta a física sobre a qual ele foi construído com dados de uma rede implantada. [Dynes et al. 2019] depositaram sob licença CC-BY os dados das figuras do artigo sobre a rede quântica metropolitana de Cambridge. Dois desses arquivos são medições sobre as quais o modelo faz previsão: 575 instantâneos diários, de novembro de 2016 a julho de 2018, da taxa de chave segura e do QBER do enlace CAPE–TREL (10,6 km, 3,9 dB; BB84 com *decoy states* a 1 GHz, $\mu = 0{,}4$, $\nu = 0{,}1$, detectores de avalanche com eficiência de 30% e *afterpulsing* de 3%); e seis medidas do QBER contra a potência recebida de um canal clássico de 100 Gbit/s multiplexado na mesma fibra.

O escopo do teste é determinado pelo conteúdo dos dados. Eles não trazem ganho nem erro por intensidade, nem contagem de vácuo, nem ataque algum; o detector, cuja metade dos atributos são observáveis de *decoy*, não pode ser avaliado sobre eles. O que se testa é a *premissa* do detector e a *física* que o gerador, o agente e o sincronizador compartilham. A Figura 6 resume os três testes.

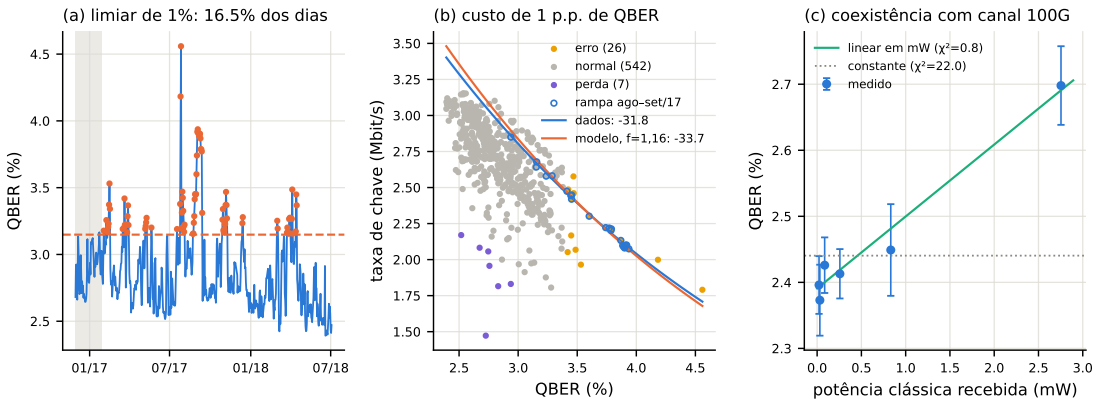


Figura 6. Dados do enlace CAPE–TREL da rede de Cambridge [Dynes et al. 2019]. (a) QBER diário; em cinza, os 60 dias de comissionamento; linha tracejada, o limiar calibrado para 1% de alarme falso; pontos, os dias em que ele dispara. (b) Taxa de chave contra QBER; círculos, a excursão de agosto–setembro de 2017; retas, a inclinação medida nela e a prevista pelo modelo; em cor, os dias classificados como degradação por erro ou por perda. (c) QBER contra a potência clássica recebida, com o ajuste linear em miliwatts e a hipótese de QBER constante.

10.1 O limiar de QBER em dias benignos

A regra implantada foi aplicada exatamente como no restante do trabalho: um período de comissionamento define média e dispersão do QBER, e o limiar é posto no quantil que dá o orçamento de alarme falso escolhido. Cada dia da série é benigno, de modo que todo alarme é falso. A Tabela 10 mostra o resultado.

Com 60 dias de comissionamento — o mesmo número de períodos de linha de base usado no simulador —, o limiar dispara em um de cada seis dias, em 17 episódios sepa-

Tabela 10. Limiar de QBER calibrado no comissionamento, aplicado aos dias seguintes da série de Cambridge. Todo alarme é falso.

Comissionamento	Orçamento	Limiar	Dias com alarme	Episódios	Acima do orçamento
30 dias	1%	3,13%	16,5%	20	16,5×
60 dias	1%	3,15%	**16,5%**	**17**	**16,5**×
90 dias	1%	3,39%	5,2%	7	5,2×
60 dias	5%	3,12%	18,8%	20	3,8×

rados ao longo de 17 meses. É a premissa da Seção 1, medida em enlace real: o QBER de uma fibra implantada se move por conta própria, e um limiar sobre ele gera alarmes pelo ambiente. Uma linha de base móvel de 30 dias reduz a taxa para 2,3%, ainda o dobro do orçamento, e tem um defeito estrutural: aprende como normal um ataque que entre em rampa, que é exatamente o perfil que o gerador adverso inclui.

10.2 O custo de um ponto de QBER

A taxa de chave absoluta depende de parâmetros que [Dynes et al. 2019] não publicam — tempo morto, perda interna do receptor, tamanho do bloco finito —, e o modelo a superestima por um fator entre 1,4 e 2,4 conforme o tempo morto assumido. A *sensibilidade* $\mathrm{d}\ln R/\mathrm{d}E_\mu$, porém, é fixada quase inteiramente pelos termos de entropia da cota GLLP (Seção 5.2) e tem pouca liberdade: é a previsão adequada para o teste. A Tabela 11 compara três estimativas nos dados com o modelo avaliado no ponto de operação publicado, variando apenas o desalinhamento.

Tabela 11. Sensibilidade da taxa de chave ao QBER, $\mathrm{d}\ln R/\mathrm{d}E_\mu$, medida no enlace CAPE–TREL e prevista pelo modelo. O custo de um ponto percentual é $1 - e^{s/100}$.

Estimativa	Inclinação	IC 95%	R^2	Custo de 1 p.p.
Série inteira	$-25{,}2$	$\pm 2{,}2$	0,46	22%
Intra-mês	$-31{,}2$	$\pm 1{,}9$	0,66	27%
Excursão ago–set/2017	$\mathbf{-31{,}8}$	$\mathbf{\pm 1{,}1}$	**0,994**	27%
Modelo, $f = 1{,}16$	$-33{,}7$	—	—	29%
Modelo, $f = 1{,}10$	$-31{,}1$	—	—	27%
Modelo, $f = 1{,}00$	$-27{,}4$	—	—	24%

A regressão sobre a série inteira é enviesada em direção a zero, e o viés tem causa física: há dias em que a taxa cai sem que o QBER se mova — perda, não erro — e variações lentas de perda ao longo do ano se sobrepõem à relação. Dois estimadores removem o confundimento. O primeiro subtrai de ambas as grandezas a média de cada mês. O segundo usa um experimento natural: entre 22 de agosto e 12 de setembro de 2017 o QBER subiu de 2,9% para 3,9% e foi corrigido em um único dia, e ao longo dessa excursão a relação é exponencial com $R^2 = 0{,}994$. Os dois concordam em $-31{,}5 \pm 1$.

O modelo, com a ineficiência de reconciliação $f = 1{,}16$ usada em todo o trabalho, prevê $-33{,}7$: 6% mais íngreme que a medida, cerca de duas vezes o intervalo de confiança. A inclinação é sensível a um único parâmetro não publicado, f, e com $f = 1{,}10$ o modelo reproduz a medida. A conclusão é que a física de taxa de chave está correta e que o valor adotado para f é conservador para um sistema com reconciliação eficiente, na linha dos códigos LDPC de taxa adaptativa que superam o Cascade [Elkouss et al. 2011].

Os dias ruins também se separam nos dois tipos de degradação que o gerador produz. Tomando a inclinação medida como referência, 26 dias têm QBER mais de dois desvios acima da mediana com a taxa sobre a reta — degradação por *erro*, a classe de deriva térmica — e 7 dias têm taxa até 47% abaixo do previsto com QBER normal — degradação por *perda*, a classe de evento de perda. A distinção que o detector aprende entre essas duas classes existe numa rede real.

10.3 Coexistência com o canal clássico

O ruído de espalhamento Raman gerado por um canal clássico na mesma fibra cresce linearmente com a potência lançada [Eraerds et al. 2010, Kumar et al. 2015], e é essa a forma do modelo de coexistência usado no trabalho. A Tabela 12 compara três formas funcionais sobre as seis medidas, ponderadas pelas barras de erro publicadas.

Tabela 12. Ajuste do QBER contra a potência clássica recebida (seis pontos).

Forma	χ^2	Graus de liberdade	p
QBER constante	22,0	5	0,0005
Linear em mW (Raman)	**0,80**	4	**0,94**
Linear em dBm	8,4	4	0,08

A forma Raman é a que os dados sustentam, e o QBER constante é rejeitado. A preferência, porém, depende quase inteiramente do ponto de maior potência (+4,4 dBm): sem ele, a hipótese constante também se ajusta ($\chi^2 = 1{,}0$), e a inclinação dos cinco pontos restantes ($0{,}065 \pm 0{,}092$ p.p./mW) é compatível com a do ajuste completo ($0{,}109 \pm 0{,}024$ p.p./mW). Trata-se de consistência, não de evidência independente.

A magnitude, por outro lado, não concorda. Com o coeficiente Raman, a largura de filtro e a janela de detecção padrão do modelo, a subida prevista é de 6,1 p.p./mW, contra 0,11 p.p./mW medidos. Como o ruído Raman é proporcional ao produto desses três parâmetros, apenas o produto é identificável; resolvendo o modelo para reproduzir a medida, ele é 88 vezes menor que o padrão. Os limites de potência clássica derivados com os valores padrão são, portanto, conservadores por aproximadamente esse fator para um receptor da classe do de Cambridge.

11 Discussão

Três achados negativos foram preservados por serem informativos. O primeiro é o divisor de feixe: uma classe que a física garante indetectável, e que serve de detector de vazamento metodológico — qualquer taxa de detecção acima do acaso ali indica artefato. O segundo é o colapso do agente especialista: treinado apenas em 50 km, recuperava toda a lacuna naquele vão e perdia 86% em 80 km, comportamento corrigido apenas com sorteio de vão em treino e com a observação do regime absoluto. O terceiro é o próprio TCN, que não supera a arquitetura que pretendia substituir.

Há também uma inversão de expectativa que vale registrar: a hipótese inicial de que a recompensa por chave provável levaria o agente a *elevar* a intensidade do *decoy*, por causa da estatística finita, é falsa no ponto de operação estudado. Em bloco de um segundo a 1 GHz, mesmo $\nu = 0{,}01$ produz dezenas de milhares de cliques de *decoy* em vão metropolitano, e o agente reproduz a prescrição assintótica. A penalidade de estatística finita só se manifesta em 80 km.

12 Limitações e Validade Externa

A limitação dominante é que os resultados de detecção e controle são *in silico*. As cotas e a taxa de chave são as publicadas [Ma et al. 2005, Gottesman et al. 2004, Tomamichel et al. 2012], os ataques são escritos como modificação dos *yields*, e os parâmetros de deriva de polarização vêm de medições em fibra implantada [Czegledi et al. 2016, Ramaswamy et al. 2026, Shi et al. 2026]. A Seção 10 valida a premissa do detector e a física de taxa de chave e de coexistência contra um enlace real, mas o detector em si não foi avaliado sobre dado de campo, e um classificador treinado aqui é ponto de partida e não detector pronto.

Essa validação tem limites próprios. Os dados publicados cobrem um único enlace, em instantâneos diários, enquanto o simulador opera com período de um segundo: testa-se a física e a premissa, não o detector na sua escala de tempo. Não há temperatura nos dados, de modo que a atribuição das excursões de QBER ao ambiente é inferida pela forma — rampas lentas, correções abruptas — e não medida; uma série de temperatura de Cambridge no mesmo período permitiria testar o termômetro, o atributo que carrega a separação entre deriva térmica e ataque. O limiar comparado é a versão calibrada, a mais forte, e não o limiar fixo do fabricante: nenhum dia da série passou de 4,6% de QBER. E a concordância em taxa é de sensibilidade, não de valor absoluto.

Há dado público para avançar além disso. [Tezzin et al. 2026] publicaram medições de longo prazo de um sistema comercial operando entre o Instituto Militar de Engenharia e o Centro Brasileiro de Pesquisas Físicas, no Rio de Janeiro, com taxa de chave, QBER, visibilidade e temperaturas interna e externa registradas em dois enlaces; o conjunto está depositado em repositório público [Tezzin et al. 2026b]. Esse dado permite recalibrar o gerador — e já contradiz uma premissa deste trabalho, pois reporta QBER médio robusto ao *nível* de temperatura, com anomalias apenas durante gradientes acentuados, magnitude inferior à adotada aqui. Confirma-se o mecanismo, corrige-se a escala. Por fim,

[Martin et al. 2024] disponibilizam, mediante solicitação, dados de rede heterogênea em produção, que é o material adequado para testar transferência entre fabricantes.

O que não existe publicamente é a outra metade: observáveis por intensidade (Q_ν, Y_0, contagens de vácuo por bloco) exportados por equipamento comercial, e enlaces sob ataque com rótulo. A literatura de *quantum hacking* publica demonstrações e figuras, não registros. Consequentemente, a validação empírica das classes PNS e cegamento — exatamente as que o limiar de QBER não enxerga — depende de experimento controlado em bancada, e não de dado disponível.

Outras limitações: apenas um ataque por episódio; o estudo de taxa de decisão tem dois pontos (1 s e 5 s); e em 80 km o agente ainda recupera apenas 19% da lacuna até o oráculo.

13 Produto Tecnológico e Reprodutibilidade

A implementação é um pacote Python que estende uma camada de física e dados para redes quânticas construída sobre o simulador de eventos discretos SeQUeNCe [Wu et al. 2021]. Os módulos novos são: a física de *decoy states*; os ataques como transformação de canal; o simulador de sessões; os detectores e seu protocolo de avaliação; o ambiente e o agente de taxa de chave; o modelo de deriva temporal com seus preditores; o compensador convolucional causal; e o módulo de validação contra os dados de [Dynes et al. 2019]. Todas as redes são implementadas em *numpy* com retropropagação manual verificada contra diferenças finitas. A suíte de testes conta 926 casos, entre os quais a verificação de que força de ataque nula é indistinguível de canal honesto, de que o limiar de decisão nulo reproduz exatamente a decisão *argmax*, e de que a convolução causal não enxerga o futuro. Os relatórios em HTML são gerados a partir dos mesmos CSV que produzem as tabelas deste artigo.

14 Conclusão

Este trabalho mostra que a distinção entre espionagem e degradação ambiental em um enlace de QKD com *decoy states* é recuperável do registro público que as duas pontas já trocam, acrescido de um termômetro. Sob avaliação adversa, um classificador por *gradient boosting* atinge F1 macro de 0,830 e detecta os quatro ataques modelados, contra um dos quatro para o limiar de QBER calibrado ao mesmo orçamento de alarme falso. As ablações localizam a separação: os observáveis de *decoy* carregam o PNS, o termômetro carrega a distinção entre deriva térmica e intercept-and-resend. Sobre a mesma física, um agente ator-crítico eleva a taxa de chave provável entre 8,8% e 18,9% sem tocar no hardware, e um preditor com termômetro sustenta janelas de detecção estreitas contra a deriva térmica do atraso.

O achado de maior consequência prática, porém, não é de modelagem: a precisão sob prior realista é governada pela taxa de decisão do enlace. Reduzir a frequência de decisão de um para cinco segundos, com limiar calibrado fora do ajuste, leva a precisão

de 0,22 a 1,00 — um ganho que nenhuma troca de classificador produziu.

Os dados de campo da rede de Cambridge sustentam os fundamentos. Em 515 dias benignos de um enlace implantado, o limiar de QBER calibrado para 1% de alarme falso disparou em 16,5% dos dias; o custo medido de um ponto de QBER, $-31{,}8 \pm 1{,}1$ em $\mathrm{d}\ln R / \mathrm{d}E_\mu$, concorda com o modelo dentro de 6%; e a penalidade de coexistência tem a forma Raman, com magnitude 88 vezes menor que a assumida por padrão. O passo seguinte é testar o termômetro contra uma série de temperatura do mesmo enlace e produzir, em bancada, os registros rotulados de ataque que a literatura ainda não publica.

Referências

Bai, S., Kolter, J. Z., and Koltun, V. (2018). An empirical evaluation of generic convolutional and recurrent networks for sequence modeling. *arXiv preprint* arXiv:1803.01271.

Bennett, C. H. and Brassard, G. (1984). Quantum cryptography: public key distribution and coin tossing. In *Proceedings of the IEEE International Conference on Computers, Systems and Signal Processing*, pages 175–179, Bangalore.

Brassard, G., Lütkenhaus, N., Mor, T., and Sanders, B. C. (2000). Limitations on practical quantum cryptography. *Physical Review Letters*, 85(6):1330–1333.

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32.

Cortes, C. and Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3):273–297.

Czegledi, C. B., Karlsson, M., Agrell, E., and Johannisson, P. (2016). Polarization drift channel model for coherent fibre-optic systems. *Scientific Reports*, 6:21217.

Diamanti, E., Lo, H.-K., Qi, B., and Yuan, Z. (2016). Practical challenges in quantum key distribution. *npj Quantum Information*, 2:16025.

Dynes, J. F., Wonfor, A., Tam, W. W.-S., Sharpe, A. W., Takahashi, R., Lucamarini, M., Plews, A., Yuan, Z. L., et al. (2019). Cambridge quantum network. *npj Quantum Information*, 5:101. Dados sob CC-BY em `https://doi.org/10.17863/CAM.44524`.

Elkouss, D., Martinez-Mateo, J., and Martin, V. (2011). Information reconciliation for quantum key distribution. *Quantum Information and Computation*, 11(3–4):226–238.

Eraerds, P., Walenta, N., Legré, M., Gisin, N., and Zbinden, H. (2010). Quantum key distribution and 1 Gbps data encryption over a single fibre. *New Journal of Physics*, 12(6):063027.

Friedman, J. H. (2001). Greedy function approximation: a gradient boosting machine. *The Annals of Statistics*, 29(5):1189–1232.

Gisin, N., Ribordy, G., Tittel, W., and Zbinden, H. (2002). Quantum cryptography. *Reviews of Modern Physics*, 74(1):145–195.

Gottesman, D., Lo, H.-K., Lütkenhaus, N., and Preskill, J. (2004). Security of quantum key distribution with imperfect devices. *Quantum Information and Computation*, 4(5):325–360.

Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., et al. (2020). Array programming with NumPy. *Nature*, 585:357–362.

Hochreiter, S. and Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*,

9(8):1735–1780.

Hwang, W.-Y. (2003). Quantum key distribution with high loss: toward global secure communication. *Physical Review Letters*, 91(5):057901.

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., and Liu, T.-Y. (2017). LightGBM: a highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems*, pages 3146–3154.

Kingma, D. P. and Ba, J. (2015). Adam: a method for stochastic optimization. In *International Conference on Learning Representations*.

Kumar, R., Qin, H., and Alléaume, R. (2015). Coexistence of continuous variable QKD with intense DWDM classical channels. *New Journal of Physics*, 17:043027.

Lo, H.-K., Ma, X., and Chen, K. (2005). Decoy state quantum key distribution. *Physical Review Letters*, 94(23):230504.

Lydersen, L., Wiechers, C., Wittmann, C., Elser, D., Skaar, J., and Makarov, V. (2010). Hacking commercial quantum cryptography systems by tailored bright illumination. *Nature Photonics*, 4(10):686–689.

Ma, X., Qi, B., Zhao, Y., and Lo, H.-K. (2005). Practical decoy state for quantum key distribution. *Physical Review A*, 72(1):012326.

Mao, Y., Huang, W., Zhong, H., Wang, Y., Qin, H., Guo, Y., and Huang, D. (2020). Detecting quantum attacks: a machine learning based defense strategy for practical continuous-variable quantum key distribution. *New Journal of Physics*, 22. DOI: 10.1088/1367-2630/aba8d4.

Martin, V., Brito, J. P., Ortíz, L., Méndez, R. B., Buruaga, J. S., Vicente, R. J., et al. (2024). MadQCI: a heterogeneous and scalable SDN-QKD network deployed in production facilities. *npj Quantum Information*, 10:80.

Mnih, V., Badia, A. P., Mirza, M., Graves, A., Lillicrap, T., Harley, T., Silver, D., and Kavukcuoglu, K. (2016). Asynchronous methods for deep reinforcement learning. In *Proceedings of the 33rd International Conference on Machine Learning*, pages 1928–1937.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., et al. (2011). Scikit-learn: machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830.

Pirandola, S., Andersen, U. L., Banchi, L., Berta, M., Bunandar, D., Colbeck, R., et al. (2020). Advances in quantum cryptography. *Advances in Optics and Photonics*, 12(4):1012–1236.

Ramaswamy, A., Rao, N. S. V., Chapman, J. C., and Alshowkan, M. (2026). Analysis of polarization drift of optical signals over deployed aerial-inground fiber connections. *arXiv preprint* arXiv:2607.07629.

Scarani, V., Bechmann-Pasquinucci, H., Cerf, N. J., Dušek, M., Lütkenhaus, N., and Peev, M. (2009). The security of practical quantum key distribution. *Reviews of Modern Physics*, 81(3):1301–1350.

Schulman, J., Moritz, P., Levine, S., Jordan, M. I., and Abbeel, P. (2016). High-dimensional continuous control using generalized advantage estimation. In *International Conference on Learning Representations*.

Shi, S., Su, Y., Rahmouni, A., et al. (2026). Entanglement distribution over a polarization-stabilized aerial fiber. *arXiv preprint* arXiv:2601.11753.

Sutton, R. S. and Barto, A. G. (2018). *Reinforcement learning: an introduction*. MIT Press, 2nd edition.

Tezzin, A., Uhdre, G. M., Martins, O., Rufo, S., and Carneiro, V. G. A. (2026a). Long-term performance analysis of a commercial QKD device under real-world deployment conditions. *arXiv preprint* arXiv:2604.16236.

Tezzin, A., Uhdre, G. M., Martins, O., Rufo, S., and Carneiro, V. G. A. (2026b). Long-term performance dataset of a commercial QKD system operating under tropical climate conditions in Rio de Janeiro, Brazil. *IEEE DataPort*. `https://ieee-dataport.org/documents/long-term-performance-dataset-commercial-qkd-system-operating-under-tropical-climate`.

Tomamichel, M., Lim, C. C. W., Gisin, N., and Renner, R. (2012). Tight finite-key analysis for quantum cryptography. *Nature Communications*, 3:634.

van den Oord, A., Dieleman, S., Zen, H., Simonyan, K., Vinyals, O., Graves, A., Kalchbrenner, N., Senior, A., and Kavukcuoglu, K. (2016). WaveNet: a generative model for raw audio. *arXiv preprint* arXiv:1609.03499.

Wang, W. and Lo, H.-K. (2019). Machine learning for optimal parameter prediction in quantum key distribution. *Physical Review A*, 100(6):062334.

Wu, X., Kolar, A., Chung, J., Jin, D., Zhong, T., Kettimuthu, R., and Suchara, M. (2021). SeQUeNCe: a customizable discrete-event simulator of quantum networks. *Quantum Science and Technology*, 6(4):045027.

Xu, F., Ma, X., Zhang, Q., Lo, H.-K., and Pan, J.-W. (2020). Secure quantum key distribution with realistic devices. *Reviews of Modern Physics*, 92(2):025002.

Xu, J., Ma, X., Liu, J., Zhang, C., Li, H., Zhou, X., and Wang, Q. (2024). Automatically identifying imperfections and attacks in practical quantum key distribution systems via machine learning. *Science China Information Sciences*, 67:202501.

Zhao, Y., Fung, C.-H. F., Qi, B., Chen, C., and Lo, H.-K. (2008). Quantum hacking: experimental demonstration of time-shift attack against practical quantum-key-distribution systems. *Physical Review A*, 78(4):042333.